Resumen

Este trabajo analiza la relación dinámica entre el *mix* de generación eléctrica, los precios energéticos y la inflación medida por el IPC en España durante el periodo 2010–2024, utilizando datos mensuales. Se estiman modelos VAR y SVAR para estudiar la transmisión de *shocks* en el precio del gas natural, en el precio mayorista de la electricidad y en la composición del *mix* de producción eléctrica hacia el IPC, y se complementa el análisis con un modelo no lineal de *machine learning* basado en XGBoost. Los resultados muestran que el precio del gas actúa como el principal impulsor externo de la volatilidad del precio mayorista de la electricidad y que existe un *pass-through* desde el precio eléctrico hacia el IPC, que opera con retardos. Asimismo, una mayor cuota de generación renovable se asocia con menores precios mayoristas y con una señal desinflacionaria posterior, aunque de magnitud moderada. El modelo de aprendizaje automático identifica no linealidades en la relación entre precios de la electricidad e inflación. La sensibilidad del precio de la electricidad y del IPC al gas aumenta cuando el precio del gas supera ciertos niveles, y el efecto del mix renovable es más visible a altas cuotas de producción.

Índice general

Resumen **1**

1. Introducción **4**
1.1. Contexto 4
1.2. Objetivos 5

2. Revisión bibliográfica **6**

3. Los datos **9**
3.1. Construcción del conjunto de datos 9
3.1.1. Armonización temporal y criterio de frecuencia 9
3.1.2. Variables del mix y agregados 10
3.1.3. Ingeniería de variables para ML 10
3.2. Análisis exploratorio de los datos 11
3.2.1. Evolución temporal y eventos recientes 11
3.2.2. Demanda y composición del *mix* eléctrico 13
3.2.3. Correlaciones entre precios, *mix* e inflación 14

4. Metodología **16**
4.1. Sistema dinámico y construcción de las variables agregadas 16
4.2. Modelo VAR en niveles y análisis de cointegración 18
4.2.1. Especificación y estimación 18
4.2.2. Selección del orden de retardos, estabilidad y cointegración 19
4.3. Del VAR reducido al SVAR con identificación de Cholesky 19
4.3.1. Forma estructural y problema de identificación 19
4.3.2. Ordenamiento recursivo y justificación económica 20
4.3.3. Funciones de impulso–respuesta y FEVD 21
4.4. Modelo XGBoost para precio eléctrico e IPC 21
4.4.1. Fundamentos teóricos: suma de árboles de decisión y función objetivo 21
4.4.2. Algoritmo de *gradient boosting* 22
4.4.3. Construcción del conjunto de predictores 23
4.4.4. Entrenamiento con validación cruzada temporal 23

4.4.5. Interpretabilidad económica: importancia de variables y efectos marginales 24

5. Resultados **25**

5.1. Resultados del VAR–SVAR con agregados del *mix* eléctrico 25

5.1.1. Propiedades estocásticas, cointegración y especificación del VAR . . 25

5.1.2. Funciones de respuesta al impulso (SVAR) 27

5.1.3. Descomposición de la varianza del error de predicción (FEVD) . . . 31

5.1.4. Capacidad predictiva y evaluación fuera de muestra (2024) 32

5.1.5. Discusión e implicaciones 35

5.2. Resultados del modelo de ML: XGBoost 36

5.2.1. El modelo XGBoost en entornos de alta dimensionalidad 36

5.2.2. Modelo XGBoost para el precio mayorista de la electricidad 37

5.2.3. Modelo XGBoost para el IPC general 42

5.2.4. Discusión de los resultados 45

6. Conclusiones **46**

7. Limitaciones y mejoras **47**

7.1. Limitaciones 47

7.2. Líneas de investigación futura 48

Capítulo 1

Introducción

1.1. Contexto

Durante el periodo 2010–2024, el sistema eléctrico español cambió de forma sustancial: el carbón perdió peso, la energía nuclear se mantuvo como generación de base y la eólica y la solar fotovoltaica crecieron con fuerza. Estos cambios son importantes porque, en un mercado marginalista, el precio mayorista lo fija la tecnología que entra en el margen[1]. En España, los ciclos combinados suelen desempeñar ese papel en muchos episodios, aunque no de forma exclusiva (por ejemplo, la hidráulica puede fijar el precio marginal en una proporción relevante de horas en ciertos periodos). (Peña 2024; Martínez et al. 2023)

Este proceso coincidió con un periodo de elevada tensión en los mercados energéticos europeos. Desde mediados de 2021 y especialmente en 2022, la reducción del gas ruso y la guerra en Ucrania elevaron los precios del gas natural, con efectos en cascada sobre los precios de la electricidad en Europa. (*Energy prices and security of supply* 2024)

En la Península Ibérica, la subida del gas se trasladó con rapidez al precio del pool, lo que aumentó la preocupación por el pass-through a precios minoristas y a la inflación. Como respuesta, en junio de 2022 se aplicó el llamado *mecanismo ibérico* ("excepción ibérica"), que limita el precio del gas utilizado por las centrales térmicas para ofertar en el mercado eléctrico, tras la aprobación de la Comisión Europea y su desarrollo normativo en España. (*Commission approves Spanish and Portuguese measures aimed at reducing the wholesale electricity price* 2022)

En paralelo, el aumento del peso de las renovables reactivó el debate sobre su capacidad para reducir el precio mayorista mediante el *merit-order effect*: cuando entran tecnologías de bajo coste marginal, desplazan generación más cara y presionan a la baja el precio de casación[2]. La evidencia empírica documenta este mecanismo y, para España, muestra

[1] En un mercado eléctrico marginalista, el precio mayorista viene determinado por la última tecnología necesaria para cubrir la demanda en cada periodo. Por ejemplo, si para satisfacer la demanda entra una central de ciclo combinado, el precio se fija en función de su coste, aunque otras tecnologías con costes más bajos (como eólica o nuclear) también estén produciendo.

[2] El precio de casación es el precio de la última oferta necesaria para cubrir la demanda en cada periodo.

efectos apreciables en periodos previos. (Gelabert et al. 2011b; Sensfuß et al. 2008)

En este contexto, este trabajo analiza empíricamente cómo la composición tecnológica del mix de generación se relaciona con el precio mayorista de la electricidad y, a través de ese canal, con la evolución del IPC en España.

1.2. Objetivos

El objetivo general de este Trabajo de Fin de Máster es estudiar la relación dinámica entre el mix de generación, los precios energéticos y la inflación (IPC) en España durante 2010–2024, combinando modelos econométricos y modelos no lineales de *machine learning*.

Objetivos específicos:

1. Describir la coevolución del precio mayorista de la electricidad, el precio del gas natural y el mix de generación, y documentar sus cambios en el tiempo.

2. Estimar, mediante modelos VAR/SVAR, la respuesta dinámica del precio eléctrico y del IPC ante shocks energéticos y cambios en la composición del mix.

3. Implementar XGBoost (*eXtreme Gradient Boosting*) para capturar no linealidades y posibles umbrales (p. ej., niveles de penetración renovable a partir de los cuales el precio cambia de tendencia).

4. Comparar VAR, SVAR y XGBoost en capacidad predictiva con evaluación *out-of-sample*.

Por ejemplo, si entra una central de gas, ese coste fija el precio para toda la energía vendida, aunque haya renovables produciendo.

Capítulo 2

Revisión bibliográfica

Shocks energéticos e inflación

La crisis energética europea reactivó el análisis del *pass-through*[1] de la energía a la inflación, con un foco creciente en el gas. López et al. (2024) estiman un B-SVAR para la zona euro y encuentran que un aumento inesperado del 10 % en el precio del gas eleva la inflación general en torno a 0,1 p.p. a un horizonte cercano a dos años. El efecto varía entre países y se relaciona con la exposición al gas en la producción y en la generación eléctrica. En la misma línea, Adolfsen et al. (2024) descomponen las variaciones del gas en *shocks* de demanda, oferta e inventarios y muestran que el impacto inflacionario depende del tipo de perturbación, siendo los *shocks* de oferta/demanda típicamente más persistentes.

Más allá del efecto medio, la literatura subraya mecanismos de amplificación. El canal de expectativas y el proceso de fijación de precios por parte de las empresas puede aumentar la persistencia del *pass-through* tras perturbaciones energéticas (Boeck y Zörner 2025). En el plano predictivo, la energía explica una fracción relevante de los errores de previsión de la inflación agregada; por ello, se han propuesto modelos bayesianos más granulares para anticipar inflación energética (gas, electricidad y combustibles) y mejorar las predicciones más allá del corto plazo (Bańbura et al. 2025).

Mercado eléctrico español y mecanismo ibérico

En España, el vínculo gas–electricidad se vio alterado por el mecanismo del tope al gas ("excepción ibérica"). Robinson et al. (2023) analizan los primeros 100 días y argumentan que la magnitud del efecto depende de cómo se construye la senda contrafactual y de si se incorpora elasticidad de demanda. Estudios con técnicas de control sintético encuentran efectos sobre precios mayoristas y una transmisión parcial a inflación, con heterogeneidad temporal y condicionada por el diseño de tarifas (Ruiz et al. 2024). A ni-

[1] El *pass-through* se refiere al grado en que una variación en los precios de una etapa del proceso productivo (por ejemplo, precios energéticos mayoristas) se traslada a precios finales al consumidor, de forma inmediata o con retardos.

vel de precios al consumidor y dinámica de mercado, análisis recientes enfatizan también efectos distributivos y cambios en incentivos y márgenes (Hidalgo-Pérez et al. 2024).

Renovables, *merit-order* y precios

El efecto *merit-order* de las renovables en España está bien documentado: una mayor entrada de generación de bajo coste marginal desplaza tecnologías más caras y reduce el precio de casación (Gelabert et al. 2011a). En el periodo reciente, el Banco de España estima que, si la generación eólica y solar se hubiese mantenido en niveles de 2019, el precio mayorista en la primera mitad de 2024 habría sido más de un 40 % superior (Quintana 2024). Informes privados llegan a conclusiones consistentes sobre el papel moderador de la expansión renovable en 2021–2024 (Cubero et al. 2025; Rabobank 2025).

A escala europea, existe evidencia empírica de que una mayor cuota de renovables se asocia con menor inflación, lo que sugiere un canal macro adicional más allá del mercado eléctrico (Markowski y Kotliński 2023). Además, la transición energética ocurre en un entorno de integración y contagio entre mercados: la volatilidad de los precios eléctricos se transmite entre países europeos, reforzando la necesidad de analizar la dinámica conjunta de precios energéticos (Cevik y Zhao 2025).

Pass-through, asimetrías y evidencia micro

La transmisión a precios finales no tiene por qué ser simétrica. La evidencia micro y sectorial muestra ajustes más rápidos ante *shocks* positivos que ante caídas, con implicaciones para la persistencia inflacionaria (Méjean 2023). En España, el *pass-through* de *commodities* energéticas también se ha estudiado para el petróleo: el impacto directo es claro en componentes energéticos, mientras que los efectos indirectos y de segunda ronda tienden a ser más moderados en promedio (Castro et al. 2017; Topan et al. 2020). En paralelo, algunos trabajos advierten que políticas basadas sólo en señales de precios pueden generar resultados no deseados (por ejemplo, en emisiones) si no se coordinan con objetivos climáticos y con el diseño de mercado (Fleschutz et al. 2020).

Síntesis y aportación del TFM

En resumen, la literatura respalda dos ideas: (i) los *shocks* del gas y los precios eléctricos influyen en la dinámica de la inflación; y (ii) la composición del *mix* de generación eléctrica condiciona el nivel y la volatilidad del precio mayorista de la electricidad. Dado esto, aparecen tres preguntas recurrentes que motivan este trabajo:

1. **Separación entre enfoques macro y sectoriales.** Gran parte de la evidencia analiza inflación agregada o formación de precios eléctricos por separado.

2. **Identificación y contrafactual.** En el mecanismo ibérico, los resultados dependen de supuestos sobre el contrafactual y la elasticidad de demanda.

3. **No linealidades.** La relación entre penetración de las fuentes renovables, tecnología marginal y precios puede presentar umbrales y cambios de régimen que modelos lineales no capturan bien.

La evidencia existente orienta, pero no elimina problemas de interpretación. En particular: (i) la endogeneidad entre demanda, precios y mix limita lecturas causales simples; (ii) los resultados pueden depender del periodo (crisis vs normalidad) y de cambios regulatorios; y (iii) medidas como el tope al gas requieren un contrafactual creíble. En consecuencia, este trabajo prioriza reportar sensibilidad a especificaciones (número de retardos, identificación en SVAR, ventanas temporales) y complementar la lectura estructural con la evaluación predictiva *out-of-sample*. O sea, este trabajo contribuye conectando el mercado eléctrico con la inflación para España con un enfoque dinámico (VAR/SVAR) y explorando no linealidades.

Capítulo 3

Los datos

3.1. Construcción del conjunto de datos

El conjunto de datos utilizado en este trabajo es mensual y cubre el periodo 2010–2024 (enero de 2010 a diciembre de 2024). Se construye integrando fuentes oficiales para capturar (i) el precio mayorista de la electricidad, (ii) la estructura del sistema eléctrico (generación por tecnología) y (iii) la inflación medida por el IPC.

Las series principales provienen de: Red Eléctrica de España (*ESIOS REE – Mercados y precios* 2024) para variables del sistema eléctrico y generación por tecnologías; la Comisión Nacional de los Mercados y la Competencia (*CNMC Data: Energía eléctrica – Precio de mercado* 2024) para el precio medio mensual de la electricidad en €/MWh con continuidad histórica; y el Instituto Nacional de Estadística (INE) para el IPC general (*INE: IPC – Índice de Precios de Consumo (metodología y series)* 2024).

El archivo del conjunto de datos generado y el script completo del análisis están disponibles en este repositorio.

3.1.1. Armonización temporal y criterio de frecuencia

Todas las series se llevaron a un formato de fecha estándar y se agregaron a frecuencia mensual. La agregación se realiza de forma coherente con la naturaleza de cada variable:

- Para precios, se utiliza el promedio mensual en €/MWh.
- Para producción por tecnología, se utiliza la generación mensual (GWh) y su participación sobre el total.
- Para el IPC, se utiliza el índice mensual directamente.

Uno de los pasos más delicados fue construir una serie homogénea del precio de la electricidad (€/MWh) para todo el periodo 2010–2024. REE publica información detallada, pero la disponibilidad histórica continua accesible puede ser limitada para reconstruir

la serie completa desde 2010 con un único origen. Para asegurar continuidad en toda la muestra, el precio mensual del MWh utilizado en este trabajo se obtiene principalmente de los archivos históricos de la CNMC, que permiten reconstruir una serie continua desde 2010. A partir de 2017, los valores de CNMC se contrastan con la información de REE/E-SIOS para verificar coherencia entre fuentes. (*CNMC Data: Energía eléctrica – Precio de mercado* 2024)

3.1.2. Variables del mix y agregados

Con el *dataset* consolidado, se construyeron variables derivadas para resumir el mix de generación. Para cada mes y tecnología k se calcula su participación:

$$share_{k,t} = \frac{GWh_{k,t}}{\sum_j GWh_{j,t}}.$$

Se calculan *shares* por tecnología (hidráulica, nuclear, carbón, fuel-gas, ciclo combinado, eólica, solar fotovoltaica, solar térmica, otras renovables, cogeneración y residuos). A partir de ellas se construyen dos agregados clave:

- **Renovables** = hidráulica + eólica + solar fotovoltaica + solar térmica + otras renovables + residuos renovables.
- **Fósiles térmicas** = carbón + fuel-gas + ciclos combinados.

Estos agregados reducen dimensionalidad y facilitan la lectura económica posterior (sustitución fósil–renovable y exposición al gas).

Para capturar patrones recurrentes del sistema (meteorología, demanda, ciclo anual), se incluyen factores estacionales asociados al mes del año. Además, se incorporan variables ficticias (*dummies*) para episodios relevantes (COVID-19, crisis del gas, inicio de la guerra de Ucrania, mecanismo ibérico, etc.). Estas variables toman valor 1 en los meses definidos como periodo del evento y 0 en el resto. Su objetivo es controlar por posibles rupturas estructurales y cambios de régimen en la estimación.

3.1.3. Ingeniería de variables para ML

Para la etapa de *machine learning* se generan variables adicionales orientadas a capturar dinámica temporal:

- **Retardos autorregresivos** de precios y variables del mix (varios meses).
- **Medias móviles** para resumir la tendencia reciente y reducir ruido de alta frecuencia.

Estas transformaciones amplían la información disponible para XGBoost y permiten capturar no linealidades y posibles umbrales. En la evaluación *out-of-sample* se construyen de forma que no exista filtración de información futura (*data leakage*): cada predicción usa únicamente información disponible hasta ese mes.

3.2. Análisis exploratorio de los datos

Antes de la estimación, se realiza un análisis exploratorio para describir las series y motivar decisiones posteriores de modelización. En las figuras siguientes, la primera banda sombreada identifica el periodo de la pandemia de COVID-19, la segunda corresponde a la vigencia del mecanismo ibérico y la línea vertical discontinua es el inicio de la guerra en Ucrania. Estas marcas se incorporan posteriormente como dummies de eventos.

3.2.1. Evolución temporal y eventos recientes

La Figura 3.1 muestra inflación moderada hasta 2020, un repunte intenso en 2021–2022 y una moderación posterior. El patrón es consistente con un episodio de shock energético y ajustes posteriores, aunque su cuantificación requiere modelos dinámicos y controles adicionales.



Figura 3.1: Evolución del IPC general en España (2010–2024) con eventos: COVID, crisis del gas, guerra de Ucrania y excepción ibérica.

La Figura 3.2 muestra estabilidad relativa del precio de la electricidad hasta 2020 y un aumento pronunciado durante 2021–2022. La corrección posterior no devuelve los precios a niveles precrisis, lo que sugiere persistencia y/o cambios de régimen.

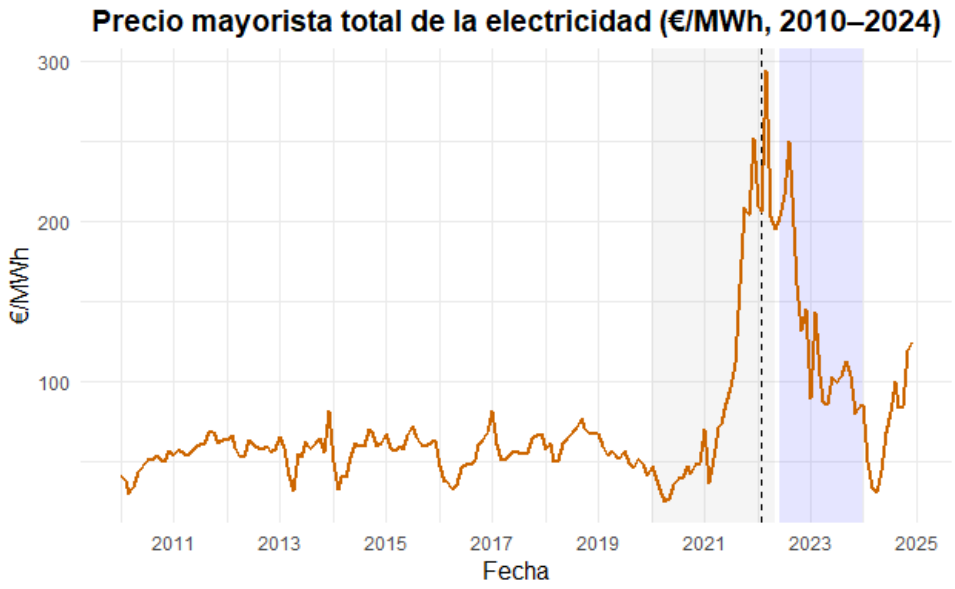


Figura 3.2: Precio mayorista total de la electricidad en España (€/MWh, 2010–2024) con eventos: COVID, crisis del gas, guerra de Ucrania y excepción ibérica.

La Figura 3.3 presenta el precio del gas natural, que sigue un patrón similar al de la electricidad, pero con máximos que aparecen antes y son más pronunciados. Esta evidencia descriptiva es coherente con el papel del gas como determinante del precio mayorista en muchos episodios, pero no permite una interpretación causal.

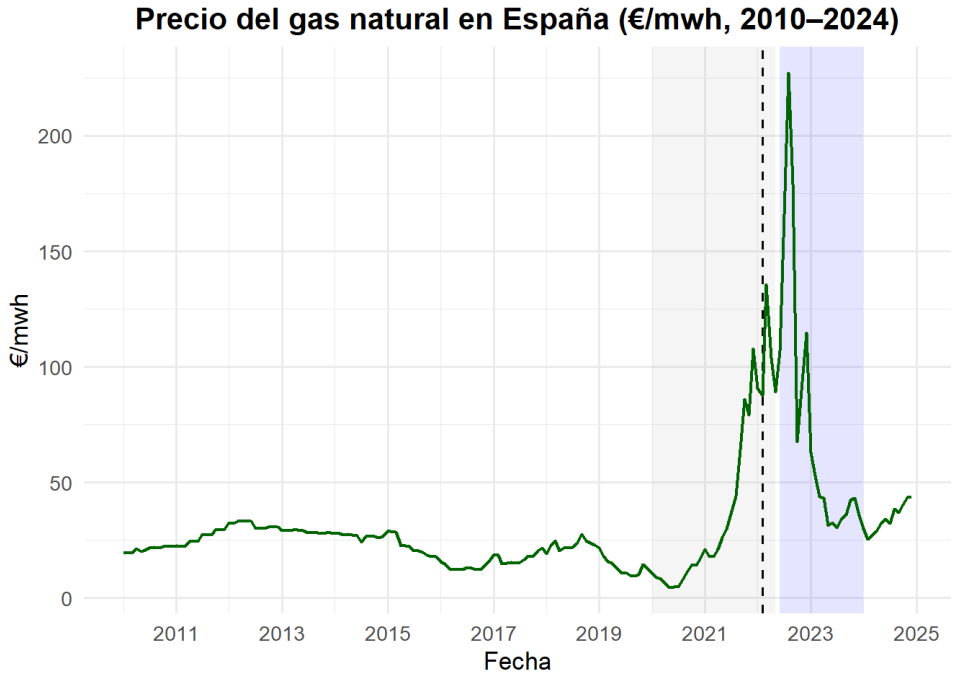


Figura 3.3: Precio del gas natural en España (€/MWh, 2010–2024) con eventos: COVID, crisis del gas, guerra de Ucrania y excepción ibérica.

3.2.2. Demanda y composición del *mix* eléctrico

La Figura 3.4 muestra la generación total de energia dentro del sistema de producción eléctrica español. Se observa una estacionalidad marcada y una caída abrupta en 2020 asociada al confinamiento. Fuera de ese episodio, no se aprecia una tendencia fuerte en la demanda agregada, lo que sugiere que buena parte de la variación de precios en 2021–2022 está más asociada a shocks de oferta (costes y tecnología marginal) que a cambios estructurales de demanda.

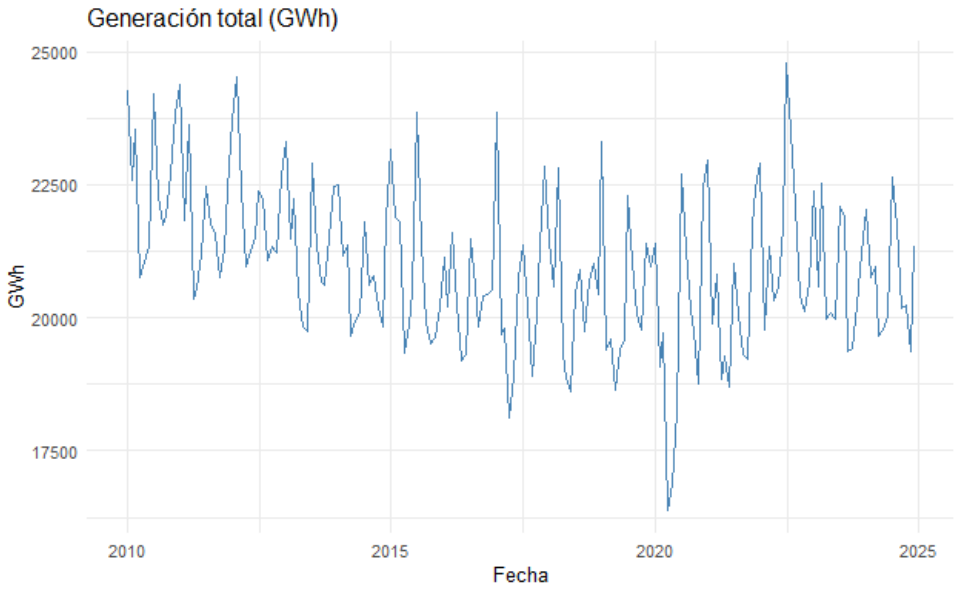


Figura 3.4: Evolución de la generación total mensual (GWh) en España (2010–2024).

La Figura 3.5 resume la evolución del mix energético: descenso de cuota fósil y aumento de cuota renovable, especialmente desde 2018, en línea con el proceso de descarbonización.

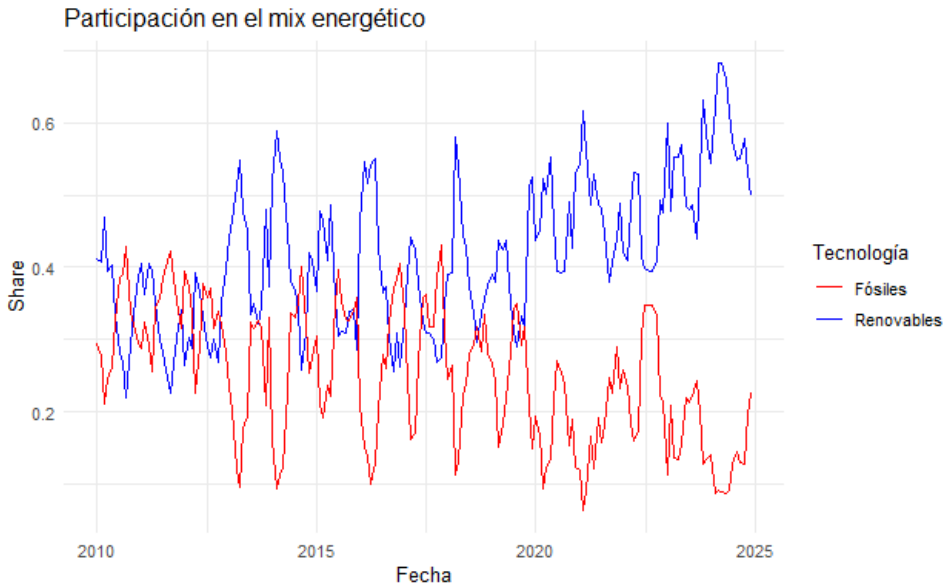


Figura 3.5: Participación de tecnologías fósiles y renovables en el *mix* eléctrico español (2010–2024).

La Figura 3.6 detalla la transición: desaparición práctica del carbón, mayor peso del ciclo combinado en episodios de tensión y expansión clara de eólica y solar. Este patrón es consistente con el *merit-order effect*: mayor renovable tiende a desplazar generación térmica más cara, lo que puede reducir el precio de casación (Gelabert et al. 2011a).

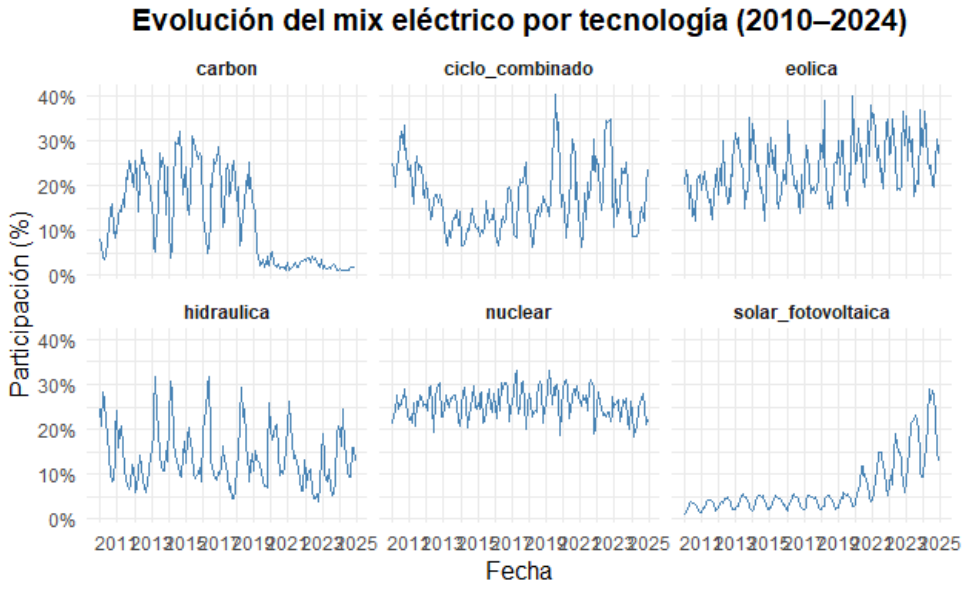


Figura 3.6: Evolución del *mix* eléctrico por tecnología: carbón, ciclo combinado, eólica, hidráulica, nuclear y solar fotovoltaica (2010–2024).

3.2.3. Correlaciones entre precios, *mix* e inflación

La Tabla 3.1 resume correlaciones contemporáneas entre las variables principales. El precio de la electricidad se asocia de manera positiva con el precio del gas ($r = 0.83$), y negativamente con la disponibilidad renovable, especialmente con las energias eólica ($r \approx -0.51$) y solar fotovoltaica ($r \approx -0.44$). Estas relaciones son coherentes con un mercado marginalista en el que (i) el gas suele actuar como tecnología marginal en episodios de tensión y (ii) la entrada de renovables desplaza generación térmica.

Tabla 3.1: Correlaciones contemporáneas entre precio eléctrico, *mix* energético e inflación (2010–2024)

Variable	Precio	Hidráulica	Nuclear	Carbón	Ciclo comb.	Eólica	Solar FV	IPC
Precio total MWh	1	−0,15*	−0,07	−0,30***	0,38***	−0,51***	−0,44***	0,40***
Hidráulica		1	0,09	0,07	−0,06	0,23***	−0,05	−0,12
Nuclear			1	−0,06	0,09	−0,17*	0,11	0,07
Carbón				1	−0,51***	−0,23**	−0,35***	0,16*
Ciclo combinado					1	−0,29***	−0,17*	0,04
Eólica						1	0,02	−0,12
Solar fotovoltaica							1	0,12
IPC general								1
Gas natural (€/MWh)	0,83***	−0,27***	0,16*	−0,27***	0,16*	−0,16	0,15*	0,34***

Nota: ** p<0.05, ** p<0.01, *** p<0.001.* Correlaciones contemporáneas con datos mensuales 2010–2024.

El IPC presenta correlación positiva con el precio de la energia eléctrica ($r \approx 0.40$) y con el gas ($r \approx 0.34$), lo que es compatible con un *pass-through* energético parcial.

En cualquier caso, estas correlaciones no se interpretan como causalidad: pueden reflejar tendencias comunes, estacionalidad o shocks simultáneos.

Capítulo 4

Metodología

El análisis empírico combina dos bloques complementarios, diseñados para responder a preguntas distintas.

En primer lugar, se especifica y estima un sistema dinámico multivariante (VAR y SVAR) sobre variables agregadas que resumen el precio de la electricidad, el precio del gas, la composición del *mix* eléctrico y el nivel de precios al consumidor. Este bloque persigue un objetivo estructural: describir la dinámica conjunta, contrastar relaciones de largo plazo y recuperar innovaciones con interpretación económica mediante un esquema de identificación recursiva a la Cholesky[1].

En segundo lugar, se construyen modelos de aprendizaje automático basados en XGBoost tanto para el precio mayorista de la electricidad como para el IPC general. El objetivo aquí es capturar no linealidades y detectar posibles umbrales. Para interpretar el modelo se emplean medidas de importancia de variables y herramientas de efectos marginales (PDP e ICE).

Ambos bloques comparten: (i) los datos mensuales 2010–2024, (ii) el mismo conjunto de controles deterministas (estacionalidad mensual) y dummies de eventos, y (iii) un esquema de evaluación fuera de muestra que reserva el año 2024 como periodo de prueba. Esta consistencia facilita comparar resultados e interpretar diferencias entre enfoques.

4.1. Sistema dinámico y construcción de las variables agregadas

A partir de la base mensual descrita en el capítulo de datos se construyen, para cada mes t, las siguientes magnitudes agregadas:

- el precio mayorista medio de la electricidad (precio_total_eur_mwh$_t$);

[1]Las *zero short-run restrictions* imponen que determinadas variables no respondan contemporáneamente a ciertos shocks estructurales, es decir, que el efecto sea nulo en el periodo inicial, lo que permite identificar el modelo SVAR.

- el precio del gas natural ($\text{precio_gas_natural_mwh}_t$);
- la participación de tecnologías renovables en la generación, definida como la suma de las cuotas de hidráulica, eólica, solar fotovoltaica, solar térmica, otras renovables y residuos renovables sobre la generación total (renovables_t);
- la participación de tecnologías fósiles y asimilables que agrupa carbón, fuel–gas, ciclo combinado, cogeneración y residuos no renovables (fosiles_t);
- el índice de precios de consumo general (ipc_general_t).

En notación compacta, el vector de variables endógenas se escribe como

$$y_t = \begin{pmatrix} \text{precio_total_eur_mwh}_t \\ \text{precio_gas_natural_mwh}_t \\ \text{renovables}_t \\ \text{fosiles}_t \\ \text{ipc_general}_t \end{pmatrix} \in \mathbb{R}^5.$$

Además, se construye un conjunto de regresores deterministas y exógenos s_t que incluye dummies mensuales de estacionalidad y cuatro dummies de eventos: `covid` (enero 2020–mayo 2022), `crisis_gas` (marzo 2021–mayo 2023), `guerra_ucrania` (desde febrero de 2022) y `excepcion_iberica` (junio 2022–diciembre 2023). Estas variables capturan desplazamientos de nivel asociados a shocks macroeconómicos y cambios regulatorios. En la práctica, ayudan a evitar que episodios extremos "contaminen" la dinámica estimada del resto de la muestra, mejorando estabilidad y capacidad descriptiva del VAR.

Se adopta una estrategia dual en la construcción de las variables del *mix* energético. Para la especificación del sistema SVAR, se trabaja con participaciones agregadas (*renovables* frente a *fósiles*) en lugar de tecnologías individuales. Esta decisión responde a parsimonia e identificabilidad: los *shares* desagregados están fuertemente correlacionados y, además, están sujetos a una restricción de suma constante, lo que complica la inversión y la interpretación de la estructura contemporánea. Desde una perspectiva económica, el mecanismo marginalista se puede aproximar razonablemente con la sustitución entre generación renovable (bajo coste marginal) y generación térmica fósil (más sensible al gas).

Por el contrario, el modelo XGBoost no está sujeto a estas limitaciones de dimensionalidad y emplea la desagregación tecnológica completa (eólica, solar, hidráulica, carbón, ciclo combinado). Esto permite explotar granularidad para capturar patrones no lineales y efectos específicos de cada tecnología que quedarían promediados en un sistema lineal agregado.

4.2. Modelo VAR en niveles y análisis de cointegración

4.2.1. Especificación y estimación

La forma reducida del sistema de ecuaciones se modeliza mediante un VAR de orden p con término constante y regresores exógenos:

$$y_t = A_1 y_{t-1} + \cdots + A_p y_{t-p} + C s_t + u_t, \tag{4.1}$$

donde $A_1, \ldots, A_p$ son matrices 5×5, C recoge los efectos de las dummies y u_t es el vector de errores reducidos, con $\mathbb{E}(u_t) = 0$ y $\mathbb{E}(u_t u_t') = \Sigma_u$, una matriz de covarianzas simétrica y definida positiva de dimensión 5×5, que recoge las varianzas y covarianzas contemporáneas entre las innovaciones de las ecuaciones del sistema.

Cada ecuación se estima por MCO, utilizando el mismo conjunto de regresores en todas ellas. Previo a la estimación se aplican contrastes ADF[2] y KPSS[3] a cada componente de y_t. En línea con la evidencia habitual en precios energéticos e inflación, se observan series muy persistentes, con indicios de raíz unitaria en niveles para precios e IPC. La combinación de ADF y KPSS, sin embargo, no siempre produce un veredicto unívoco, lo que es compatible con cambios estructurales.

Dado que las pruebas de Johansen[4] (sección siguiente) muestran evidencia de cointegración entre el precio de la electricidad, el gas, el *mix* energético y el IPC, y siguiendo el enfoque de Sims et al. (1990), se estima el VAR en niveles con constante y dummies de eventos, de modo que las relaciones de largo plazo queden incorporadas implícitamente en la dinámica del sistema. Este enfoque permite trabajar con funciones impulso–respuesta en niveles sin eliminar la información contenida en la cointegración (y evitando imponer una estructura VECM explícita cuando el objetivo es comparar también con modelos predictivos)[5].

[2]El contraste ADF (Augmented Dickey–Fuller) evalúa la hipótesis nula de raíz unitaria en una serie temporal, frente a la alternativa de estacionariedad.

[3]El contraste KPSS (Kwiatkowski–Phillips–Schmidt–Shin) plantea como hipótesis nula la estacionariedad de la serie, frente a la alternativa de presencia de una raíz unitaria.

[4]El procedimiento de Johansen permite contrastar la existencia y el número de relaciones de cointegración entre varias series temporales no estacionarias mediante un sistema VAR, utilizando las estadísticas de traza y de máximo autovalor.

[5]Aunque la presencia de cointegración permitiría formular un VECM, este impone explícitamente una estructura de corrección del error y un mecanismo de ajuste hacia el equilibrio de largo plazo. En este trabajo se opta por estimar el VAR en niveles, que describe la dinámica conjunta de las variables sin imponer dicha estructura, y facilitando la comparación con modelos predictivos que no incorporan relaciones de equilibrio explícitas.

4.2.2. Selección del orden de retardos, estabilidad y cointegración

El orden máximo de retardos considerado es $p_{\text{máx}} = 24$, equivalente a dos años completos a frecuencia mensual. En los datos agregados, AIC y FPE se minimizan en $p = 12$, mientras que HQ y SC son más conservadores[6].

Para el análisis estructural y para el ejercicio de predicción se fija $p = 6$. Se prioriza captar ciclicidad anual y propagación lenta de shocks sobre parsimonia estricta. Esta elección es coherente con: (i) alta persistencia de precios energéticos, (ii) ajustes graduales en contratos/facturación, y (iii) propagación de shocks grandes durante varios trimestres.

Una vez estimado el VAR(6), se comprueba la estabilidad analizando autovalores de la matriz companion mediante `roots`. Si todos quedan dentro del círculo unidad, el VAR admite una representación MA infinita bien definida:

$$y_t = \mu + \Psi_0 u_t + \Psi_1 u_{t-1} + \Psi_2 u_{t-2} + \dots,$$

donde Ψ_h recoge el efecto acumulado de los errores reducidos a distintos horizontes.

Sobre el vector de variables agregadas se realiza un análisis de cointegración mediante el procedimiento de Johansen, utilizando tanto la estadística de traza como la de autovalor máximo.

4.3. Del VAR reducido al SVAR con identificación de Cholesky

4.3.1. Forma estructural y problema de identificación

El VAR reducido de la ecuación (4.1) no permite interpretar u_t como *shocks* económicos puros, ya que cada componente mezcla perturbaciones de oferta, demanda, regulación y shocks internacionales. Para dotar de significado a las innovaciones se recurre a un SVAR:

$$B_0 y_t = B_1 y_{t-1} + \dots + B_p y_{t-p} + D s_t + \varepsilon_t, \tag{4.2}$$

donde ε_t es el vector de *shocks* estructurales, normalizado con $\mathbb{E}(\varepsilon_t) = 0$ y $\mathbb{E}(\varepsilon_t \varepsilon_t') = I_5$, y B_0 recoge relaciones contemporáneas entre las variables endógenas.

Las formas reducida y estructural se relacionan a través de

$$A_i = B_0^{-1} B_i, \qquad C = B_0^{-1} D, \qquad u_t = B_0^{-1} \varepsilon_t,$$

[6] AIC, FPE, HQ y SC son criterios de información para la selección del orden del VAR, que equilibran ajuste y complejidad mediante penalizaciones de distinta intensidad.

por lo que la matriz de covarianzas reducida cumple

$$\Sigma_u = \mathbb{E}(u_t u_t') = B_0^{-1}(B_0^{-1})'.$$

El problema de identificación es recuperar B_0 a partir de Σ_u. Dado que B_0 tiene $5^2 = 25$ parámetros y Σ_u sólo aporta $5 \cdot 6/2 = 15$ momentos independientes, se requieren $25 - 15 = 10$ restricciones adicionales. Este problema se aborda tal y como se describe en la siguiente sección.

4.3.2. Ordenamiento recursivo y justificación económica

En este trabajo se adopta una identificación recursiva tipo Cholesky (Lütkepohl 2005). Para ello se reordena el vector y_t como

$$y_t^* = \begin{pmatrix} \text{precio_gas_natural_mwh}_t \\ \text{precio_total_eur_mwh}_t \\ \text{fosiles}_t \\ \text{renovables}_t \\ \text{ipc_general}_t \end{pmatrix},$$

e imponemos que B_0 sea triangular inferior. Bajo esta estructura, la descomposición de Cholesky de Σ_u identifica B_0^{-1} y permite recuperar ε_t como $\varepsilon_t = B_0 u_t$.

El ordenamiento se apoya en argumentos económicos explícitos (y, por tanto, debe entenderse como una hipótesis de identificación, no como un hecho incuestionable):

1. **Precio del gas natural.** Se sitúa al principio bajo la hipótesis de "país pequeño": el precio del gas en España viene determinado por mercados internacionales y tensiones geopolíticas, por lo que no reacciona contemporáneamente a shocks domésticos de demanda eléctrica o inflación (Kilian 2009).

2. **Precio mayorista de la electricidad.** En un sistema marginalista, el precio eléctrico reacciona de inmediato a variaciones del coste del gas, pero no se considera que influya en el mercado internacional de gas dentro del mismo mes.

3. **Cuotas fósiles y renovables.** La generación fósil actúa como respaldo (*swing producer*) y ajusta producción ante cambios en precios relativos. La cuota renovable está más condicionada por capacidad instalada y meteorología, y muestra mayor inercia mensual.

4. **IPC general.** Se coloca al final por rigidez de precios al consumo (*price stickiness*). Aunque el IPC absorbe costes energéticos acumulados, no se asume retroalimentación contemporánea desde el IPC hacia mercados mayoristas energéticos dentro del mismo mes t (Sims 1980).

Con este orden, los shocks estructurales se interpretan (de forma simplificada) como: shock exógeno en el gas; shock residual del mercado eléctrico; shock en generación fósil; shock en generación renovable; y shock propio del IPC.

4.3.3. Funciones de impulso–respuesta y FEVD

Una vez identificado B_0, la representación MA estructural se escribe como

$$y_t^* = \mu + \Phi_0\varepsilon_t + \Phi_1\varepsilon_{t-1} + \Phi_2\varepsilon_{t-2} + \dots, \qquad \Phi_h = \Psi_h B_0^{-1}.$$

A partir de esta representación se calculan funciones de impulso–respuesta (IRFs) ortogonales para horizontes de hasta 12 meses. Las IRFs cuantifican, por ejemplo, la respuesta del precio eléctrico ante un shock unitario en el gas o el ajuste del IPC tras innovaciones en la cuota fósil/renovable.

Además, se construye la descomposición de varianza de los errores de predicción (FEVD). La FEVD asigna, por horizonte y variable, el porcentaje de la varianza del error de predicción atribuible a cada shock estructural. Esto permite evaluar la importancia relativa de los canales gas–electricidad, *mix* fósil/renovable e inflación.

4.4. Modelo XGBoost para precio eléctrico e IPC

El segundo bloque metodológico utiliza modelos XGBoost para aproximar de forma flexible y no lineal la relación entre el *mix* eléctrico y los precios (Chen y Guestrin 2016). El objetivo es aproximar, para cada variable de interés y_t (precio mayorista de la electricidad o IPC general), una función desconocida

$$\hat{y}_t = f(X_t),$$

donde X_t es el conjunto de predictores construido a partir de los *shares* tecnológicos, el precio del gas, dummies de eventos y un conjunto amplio de rezagos de precios y del *mix*. Aunque el modelo es estático en forma, la inclusión sistemática de rezagos permite representar dinámica temporal de forma flexible.

4.4.1. Fundamentos teóricos: suma de árboles de decisión y función objetivo

El algoritmo XGBoost representa la función $f(\cdot)$ como una suma de M árboles de decisión:

$$\hat{y}_t = f(X_t) = \sum_{m=1}^{M} \eta\, T_m(X_t), \tag{4.3}$$

donde cada $T_m(\cdot)$ es un árbol de regresión y $\eta \in (0, 1]$ es la tasa de aprendizaje.

Un árbol de regresión particiona el espacio de predictores en J_m regiones disjuntas $R_{1m}, \ldots, R_{J_m m}$ mediante reglas del tipo "si share_eolica$_t \leq 0{,}25$ y precio_gas$_{t-1} > 40$, entonces...". A cada región se le asigna un peso constante w_{jm}, de modo que el árbol puede escribirse como

$$T_m(X_t) = \sum_{j=1}^{J_m} w_{jm}\, \mathbf{1}\{X_t \in R_{jm}\}.$$

El modelo se estima minimizando una función objetivo global que combina ajuste y penalización por complejidad. Para $\{(X_t, y_t)\}_{t=1}^{T}$,

$$\mathcal{L}(f) = \sum_{t=1}^{T} \ell\Big(y_t, \hat{y}_t\Big) + \sum_{m=1}^{M} \Omega(T_m), \tag{4.4}$$

donde $\ell(\cdot)$ es la pérdida y $\Omega(\cdot)$ regulariza.

Se utiliza pérdida cuadrática,

$$\ell\Big(y_t, \hat{y}_t\Big) = \Big(y_t - \hat{y}_t\Big)^2,$$

lo que centra el entrenamiento en minimizar RMSE.

El término de regularización evita sobreajuste:

$$\Omega(T_m) = \gamma\, J_m + \frac{\lambda}{2} \sum_{j=1}^{J_m} w_{jm}^2. \tag{4.5}$$

El primer componente penaliza árboles grandes; el segundo penaliza pesos extremos. Valores mayores de γ y λ inducen árboles más pequeños y predicciones más suaves.

4.4.2. Algoritmo de *gradient boosting*

La estimación de XGBoost se interpreta como un procedimiento iterativo de *gradient boosting*. Dado un modelo en la iteración $(m-1)$, con predicciones $\hat{y}_t^{(m-1)}$, se busca un nuevo árbol T_m que reduzca la pérdida añadiendo una corrección:

$$\min_{T_m} \sum_{t=1}^{T} \ell\Big(y_t,\ \hat{y}_t^{(m-1)} + \eta T_m(X_t)\Big) + \Omega(T_m).$$

XGBoost aproxima esta minimización con una expansión de segundo orden alrededor de las predicciones actuales,

$$\ell(y_t, \hat{y}_t^{(m-1)} + \delta) \approx \ell(y_t, \hat{y}_t^{(m-1)}) + g_t \delta + \frac{1}{2} h_t \delta^2,$$

donde g_t y h_t son el gradiente y la derivada segunda respecto a $\hat{y}_t$. Para pérdida cuadrática, ambos se relacionan directamente con los residuos.

Con esta aproximación, el problema se reduce a la optimización eficiente de términos cuadráticos: el algoritmo elige divisiones que maximizan reducción de pérdida neta de la penalización por complejidad. Tras fijar T_m, se actualiza

$$\hat{y}_t^{(m)} = \hat{y}_t^{(m-1)} + \eta T_m(X_t),$$

repitiendo hasta M iteraciones o hasta que la mejora en validación sea despreciable.

En este trabajo, este esquema permite aprender patrones complejos sin especificarlos a priori: no linealidades en el efecto de la eólica, interacciones entre *mix* fósil y gas, o cambios de sensibilidad entre periodos normales y periodos de crisis.

4.4.3. Construcción del conjunto de predictores

Para aproximar directamente la formación de precios, tanto para precio_total_eur_mwh$_t$ como para ipc_general$_t$, se construye un conjunto de predictores X_t más rico que el utilizado en el VAR, a partir de la base `data` ordenada cronológicamente.

En el caso del precio de la electricidad, X_t incluye: todos los *shares* tecnológicos (`share_hidraulica`, `share_eolica`, `share_ciclo_combinado`, etc.), los shares agregados `share_renovables` y `share_fosiles`, el precio del gas, las dummies de eventos (`covid`, `crisis_gas`, `guerra_ucrania`, `excepcion_iberica`), el mes del año codificado como factor numérico y un conjunto amplio de retardos de hasta 12 meses para las variables clave (precio eléctrico, IPC, shares, precio del gas y dummies). La función auxiliar `make_lags` genera automáticamente estos retardos, de modo que el número de predictores finales alcanza del orden de varios centenares.

Para el modelo de IPC se repite la misma lógica, pero ahora la variable objetivo es `ipc_general` y se incluye además el propio precio eléctrico (nivel y rezagos) como predictor.

En ambos casos se realiza un corte temporal en diciembre de 2023: las observaciones hasta dicha fecha se usan para entrenar los modelos y el año 2024 se reserva para evaluación fuera de muestra, de forma análoga al VAR.

4.4.4. Entrenamiento con validación cruzada temporal

El entrenamiento se realiza con `caret` (método `xgbTree`) y validación cruzada adaptada a series temporales. `createTimeSlices` genera subconjuntos de entrenamiento/validación que respetan el orden temporal: cada *slice* entrena con una ventana inicial y valida en un bloque posterior, desplazando progresivamente la ventana con ventana fija. Así se evita *look-ahead bias* (Bergmeir y Benítez 2012; Hyndman y Athanasopoulos 2018).

Sobre estos *slices* se seleccionan hiperparámetros en una rejilla (*grid search*): número de árboles (`nrounds`), profundidad (`max_depth`), tasa de aprendizaje (`eta`), fracción de

columnas y observaciones por árbol (`colsample_bytree`, `subsample`) y peso mínimo en hojas (`min_child_weight`). Con los hiperparámetros fijados, se entrena el modelo final con datos hasta 2023 y se predice 2024.

Los errores fuera de muestra se evalúan con RMSE y MAPE, en paralelo al VAR. Además, se construyen gráficos tipo *fan chart* con bandas aproximadas

$$\hat{y}_t \pm 1{,}64\,\sigma,$$

donde σ es la desviación estándar de los residuos en el entrenamiento. Estas bandas no son intervalos probabilísticos exactos, pero ofrecen una referencia simple de incertidumbre alrededor de la predicción puntual.

4.4.5. Interpretabilidad económica: importancia de variables y efectos marginales

Aunque XGBoost es un modelo no paramétrico, se pueden extraer conclusiones económicas mediante interpretabilidad *a posteriori*. Se utiliza el paquete de R `iml` (interpretable machine learning) en dos frentes.

Primero, se calcula importancia de variables (`FeatureImp`) con pérdida RMSE. La idea es cuantificar cuánto empeora el error cuando se permuta aleatoriamente un predictor, manteniendo fijos los demás. Un gran deterioro sugiere que el predictor aporta información relevante. Para mantener interpretación, el análisis se restringe a un subconjunto manejable: shares tecnológicos y agregados, precio del gas, dummies de eventos y algunos rezagos seleccionados.

Segundo, se estudian efectos marginales mediante PDP e ICE con `FeatureEffect`. Para x_j,

$$f_j(x_j) = \mathbb{E}_{X_{-j}}\Big[f(x_j, X_{-j})\Big],$$

aproximada por el promedio sobre la muestra al fijar x_j en una rejilla. Las ICE trazan $f(x_j, X_{-j}^{(i)})$ para cada observación i, revelando heterogeneidad entre meses.

Para facilitar lectura económica, las predicciones se expresan como variaciones porcentuales respecto a la media muestral. Si $\bar{y}$ es la media de la variable objetivo,

$$\Delta\hat{y}(x_j) = \frac{f_j(x_j) - \bar{y}}{\bar{y}} \times 100,$$

de modo que $\Delta\hat{y}(x_j) = -5$ indica que, para ese rango de x_j, el modelo asocia una reducción media del 5 % respecto al nivel histórico medio.

Capítulo 5

Resultados

5.1. Resultados del VAR–SVAR con agregados del *mix* eléctrico

En esta sección se presentan los resultados del sistema VAR/SVAR estimado con cinco variables endógenas: el precio del mercado mayorista `precio_total_eur_mwh`, el precio del gas natural `precio_gas_natural_mwh`, las participaciones agregadas de generación `renovables` y `fosiles`, y la inflación `ipc_general`. El objetivo es describir la dinámica conjunta, evaluar la respuesta ante *shocks* e interpretar canales de transmisión compatibles con la estructura del mercado eléctrico y la inflación.

5.1.1. Propiedades estocásticas, cointegración y especificación del VAR

Los contrastes de raíces unitarias (ADF y KPSS) muestran un patrón típico de series macroeconómicas y energéticas con elevada persistencia: en la mayoría de variables el ADF no rechaza claramente raíz unitaria (RU) en niveles, mientras que el KPSS rechaza estacionariedad en nivel. En la práctica, esto es compatible con procesos cercanos a $I(1)$ (integrado de orden 1), o estacionarios con cambios de régimen. En este contexto, diferenciar sistemáticamente todas las series puede eliminar información sobre relaciones de equilibrio entre precios energéticos, composición del *mix* e inflación.

El análisis de cointegración de Johansen confirma esta intuición: tanto la estadística de traza como la de máximo autovalor rechazan de forma contundente la hipótesis de ausencia de cointegración y apuntan a la existencia de varias relaciones de largo plazo entre las cinco variables. Esto es coherente con una visión económica en la que el precio de la electricidad, el precio del gas y el IPC están vinculados por restricciones tecnológicas, institucionales y de costes, mientras que las cuotas renovables y fósiles capturan la estructura productiva subyacente.

Tabla 5.1: Resumen de estacionariedad en niveles (ADF y KPSS, 5 %)

Variable	**ADF (5 %)**	**KPSS (5 %)**	**Conclusión práctica**
`precio_total`	Rechaza RU	Rechaza estac.	Mixto / muy persistente (cercana a $I(1)$)
`precio_gas`	No rechaza RU	Rechaza estac.	Compatible con $I(1)$
`renovables`	No rechaza RU	Rechaza estac.	Compatible con $I(1)$
`fosiles`	No rechaza RU	Mixto	Mixto (posible estac. en tendencia)
`ipc_general`	No rechaza RU	Rechaza estac.	Compatible con $I(1)$

Nota: "RU" denota raíz unitaria (ADF: H_0 = raíz unitaria; KPSS: H_0 = estacionariedad). La conclusión práctica resume la evidencia conjunta al 5 %.

Tabla 5.2: Resumen del análisis de cointegración (variables agregadas)

Elemento	**Resultado**	**Implicación**
Muestra	$N = 180$ (mensual)	Base suficiente para contraste Johansen
Selección de retardos	AIC=12, HQ=6, SC=2, FPE=10	Criterios penalizan complejidad de forma distinta
Johansen (traza)	$\hat{r} = 3$ (5 %)	Existen 3 relaciones de largo plazo
Johansen (máx. autovalor)	$\hat{r} = 3$ (5 %)	Confirmación del rango

Dado este equilibrio de largo plazo, se estima el VAR en niveles, siguiendo el enfoque clásico para sistemas con posibles raíces unitarias cuando el interés se centra en dinámica e inferencia del sistema (Sims et al. 1990).

Selección del orden de retardos y estabilidad

Para seleccionar el número de retardos, se evaluaron criterios de información. El criterio de AIC sugiere una estructura más compleja ($p = 12$), mientras que HQ recomienda $p = 6$ y SC es más conservador. Se adopta $p = 6$ por parsimonia, buscando reducir sobreparametrización y preservar grados de libertad en una muestra mensual.

Los diagnósticos de estabilidad apoyan esta elección: el diagrama de raíces del polinomio característico muestra que todas las raíces se sitúan dentro del círculo unitario (Fig. 5.1). La cercanía de algunas raíces a la frontera es consistente con un sistema estable pero muy persistente, lo que es razonable en precios energéticos e inflación.

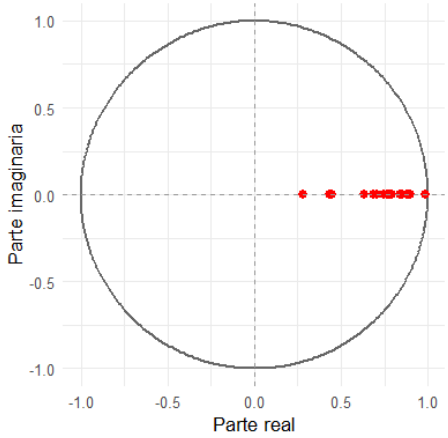


Figura 5.1: Diagrama de raíces del VAR. Todas las raíces se encuentran dentro del círculo unitario.

5.1.2. Funciones de respuesta al impulso (SVAR)

Las funciones impulso–respuesta (IRFs) describen cómo un *shock* identificado en una variable se transmite al resto del sistema. Las bandas de confianza reflejan incertidumbre: cuando incluyen el cero, la evidencia es débil y la interpretación debe ser prudente.

El SVAR se identifica mediante un esquema recursivo (Cholesky). Esto impone restricciones contemporáneas: los resultados deben interpretarse como condicionales a ese ordenamiento (Lütkepohl 2005).

Shock en el precio del gas natural

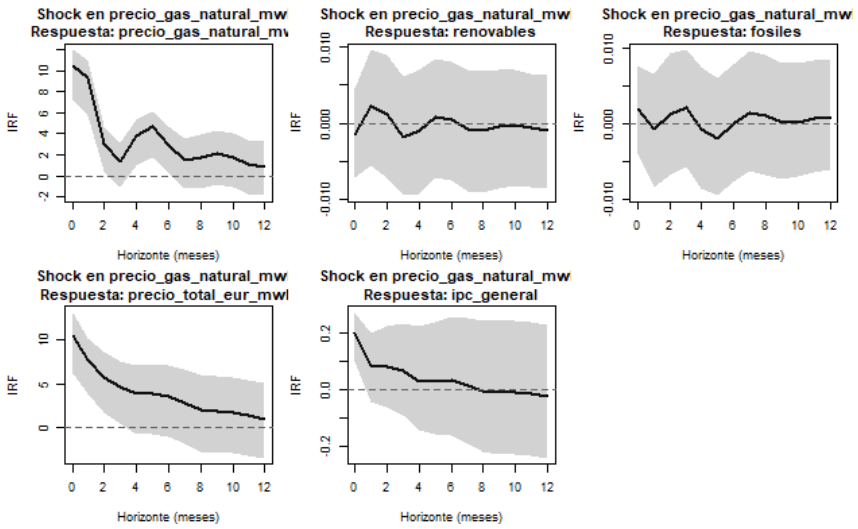


Figura 5.2: Funciones impulso–respuesta ante un shock en el precio del gas natural.

La Fig. 5.2 muestra la respuesta ante un aumento inesperado del precio del gas. La propia serie presenta un salto inicial y una trayectoria persistente que se va corrigiendo gradualmente, coherente con shocks energéticos con dinámica prolongada.

El precio mayorista de la electricidad responde de forma clara al alza en los primeros meses y se va disipando hacia el año. Económicamente, esto es consistente con el funcionamiento de un mercado marginalista en el que el gas participa con frecuencia en el margen: un encarecimiento del combustible tiende a trasladarse al precio de casación en el corto plazo.

Las respuestas de `renovables` y `fosiles` son pequeñas y poco precisas a frecuencia mensual. Esto sugiere que, una vez controlado por el resto del sistema, el *mix* no reacciona de forma rápida y sistemática ante un shock "puramente gasista", probablemente por restricciones físicas (capacidad instalada, limitación hidráulica) y por decisiones operativas que no se ajustan instantáneamente.

Por último, la respuesta del `ipc_general` es modesta y con bandas amplias. En este sistema, el canal principal hacia inflación parece operar más a través del precio eléctrico que a través del gas de forma directa.

Shock en la participación de tecnologías fósiles

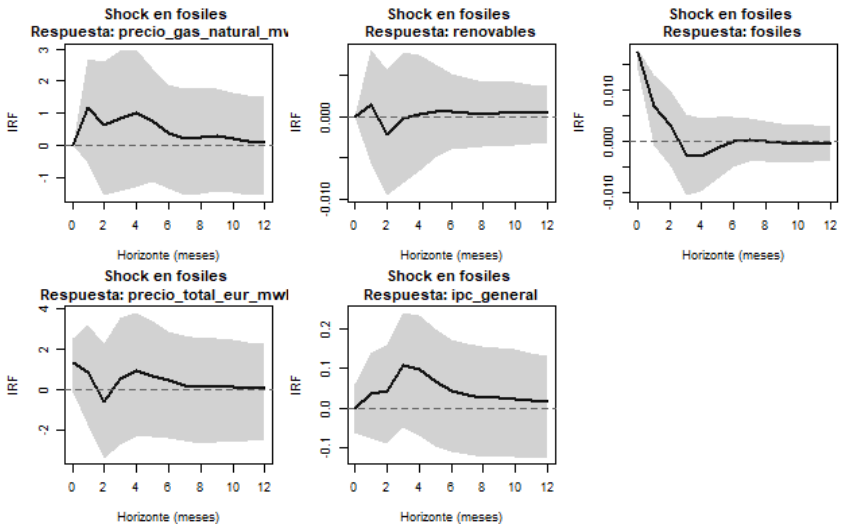


Figura 5.3: Funciones impulso–respuesta ante un shock en la cuota de tecnologías fósiles.

Ante un shock positivo en `fosiles` (Fig. 5.3), la propia variable aumenta de forma persistente. La participación `renovables` reacciona en sentido opuesto en los primeros meses, lo que es coherente con sustitución fósil–renovable en términos de cuota.

El impacto sobre precios es menos preciso: ni el gas ni el precio eléctrico muestran una respuesta robusta y monotónica. A nivel económico, esto sugiere que variaciones marginales en cuota fósil, a frecuencia mensual y condicionadas al resto del sistema, no implican necesariamente cambios netos grandes en el precio promedio mensual; el efecto puede depender del momento de casación (qué tecnología fija precio) y de cómo se distribuye la sustitución por horas.

La respuesta del `ipc_general` apunta a un aumento leve a medio plazo, pero con incertidumbre elevada. Por tanto, el signo es compatible con un *mix* más intensivo en térmicas (mayor coste marginal esperado), pero el tamaño del efecto debe interpretarse con cautela.

Shock en la participación de renovables

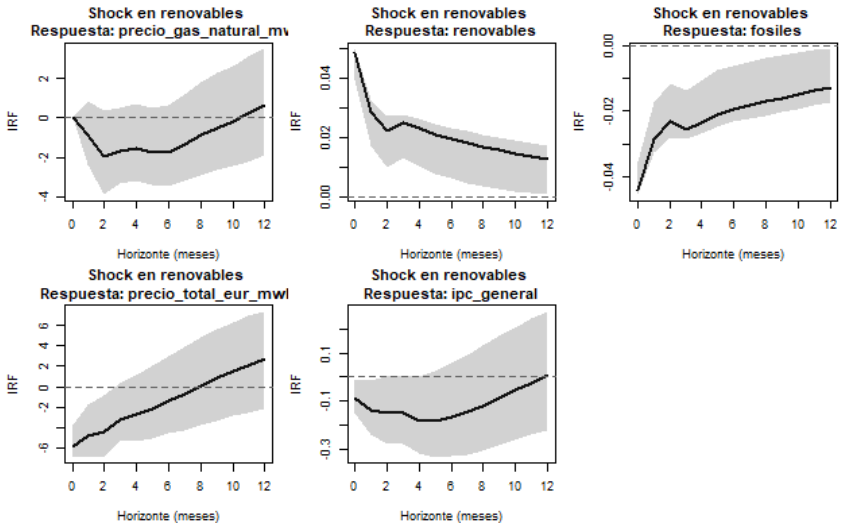


Figura 5.4: Funciones impulso–respuesta ante un shock en la cuota de renovables.

La Fig. 5.4 recoge la reacción ante un aumento inesperado de `renovables`. La propia cuota aumenta de forma persistente y `fosiles` se reduce inicialmente, lo que respalda la interpretación del shock como un aumento exógeno de disponibilidad renovable (meteorología o capacidad efectiva) a frecuencia mensual.

El efecto sobre el precio eléctrico es negativo, aunque moderado y con significación parcial. El signo es consistente con el *merit-order effect*: mayor entrada de tecnologías de bajo coste marginal presiona a la baja el precio de casación, aunque la magnitud mensual queda amortiguada por el control del gas y por episodios extremos.

La respuesta del `ipc_general` sugiere un efecto desinflacionario con retraso (aprox. 6–9 meses), antes de revertir gradualmente. Dado que las bandas son amplias, el resultado debe leerse como evidencia compatible con un papel amortiguador de la mayor cuota renovable, no como una estimación causal cerrada.

Shock en el precio mayorista de la electricidad

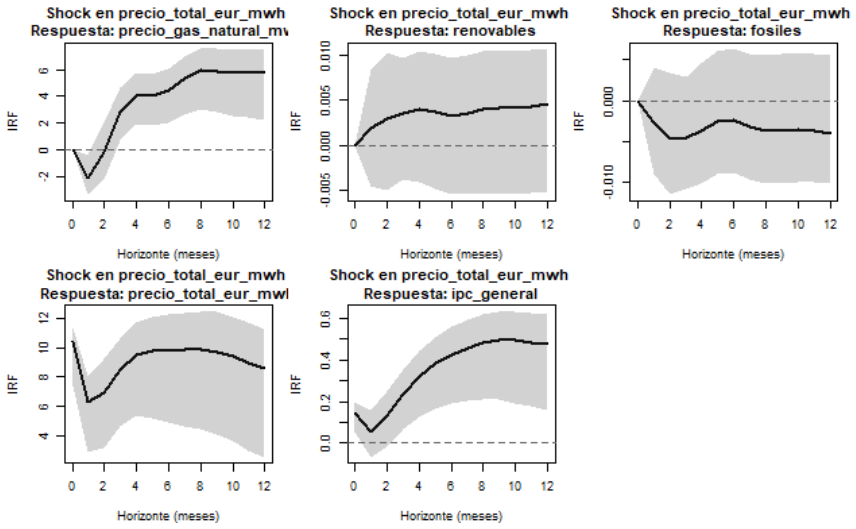


Figura 5.5: Funciones impulso–respuesta ante un shock en el precio mayorista de la electricidad.

Cuando el shock recae directamente sobre `precio_total_eur_mwh` (Fig. 5.5), la propia variable aumenta de inmediato y se corrige de forma gradual, reflejando persistencia. El gas responde positivamente, lo que es compatible con factores comunes (tensiones energéticas internacionales) o con co-movimiento entre mercados.

La composición del *mix* se ajusta en la dirección esperada, aunque con efectos pequeños: un encarecimiento inesperado se asocia con más cuota fósil y menos renovable. Esta señal es consistente con periodos de menor disponibilidad renovable que requieren más térmica y elevan el precio, aunque la precisión estadística es limitada.

El resultado más relevante es la respuesta del `ipc_general`: un shock positivo en el precio mayorista se transmite a inflación con un perfil creciente en los primeros meses y cierto aplanamiento posterior. Esto cuantifica un *pass-through* desde el mercado eléctrico hacia el IPC que opera con retrasos, compatible con mecanismos de facturación, contratos y traslación de costes.

Shock en la inflación

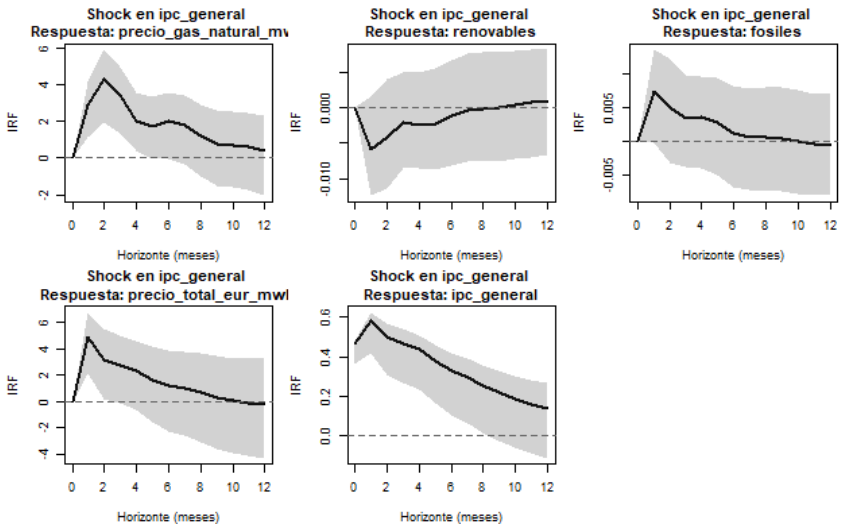


Figura 5.6: Funciones impulso–respuesta ante un shock en el IPC general.

La Fig. 5.6 muestra que un shock propio del IPC es altamente persistente. En cambio, los efectos sobre el precio eléctrico, el gas y el *mix* son pequeños y poco precisos. Este patrón es coherente con el ordenamiento recursivo adoptado (y con rigideces nominales), en el que la energía actúa como impulsor de inflación más que al revés en el corto plazo.

5.1.3. Descomposición de la varianza del error de predicción (FEVD)

La FEVD cuantifica qué parte de la incertidumbre de cada variable se explica por cada shock estructural a distintos horizontes. La Fig. 5.7 resume resultados hasta 25 meses.

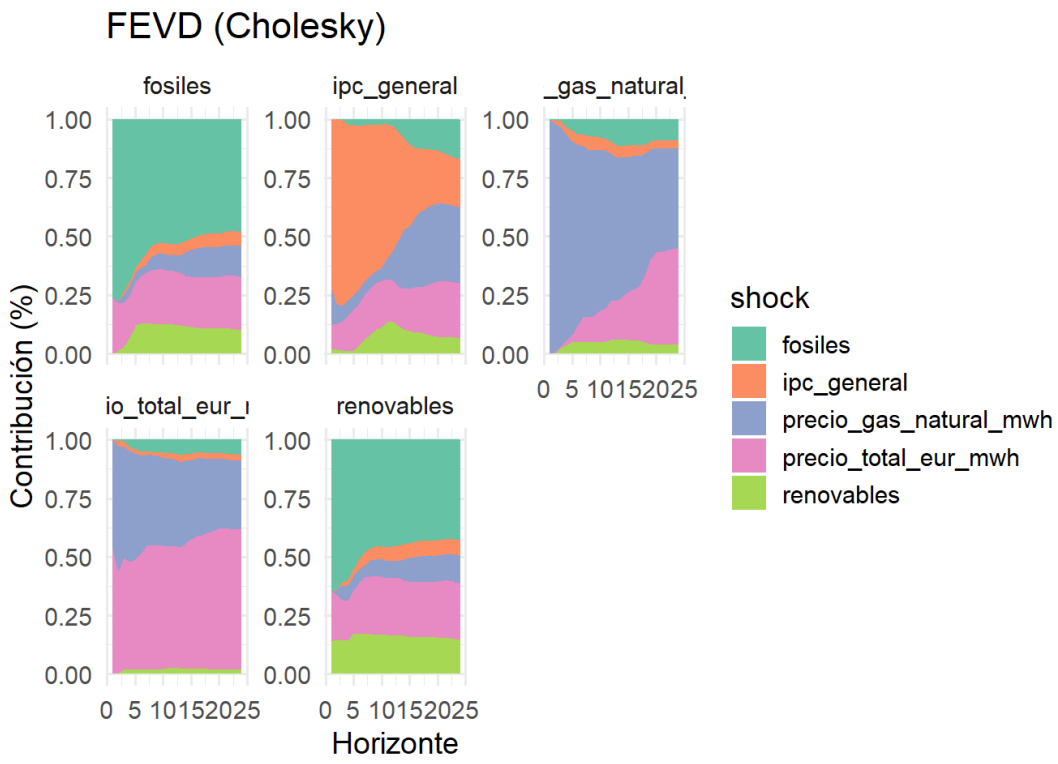


Figura 5.7: Descomposición de la varianza del error de predicción (FEVD) para cada variable del sistema.

Para el precio del gas, la varianza está dominada por shocks propios durante todo el horizonte, lo que refuerza la interpretación del gas como variable principalmente exógena para la economía española.

Para el precio mayorista, a corto plazo una fracción relevante se explica por shocks del gas; a medida que aumenta el horizonte, los shocks propios de electricidad ganan peso. Esto sugiere que, aunque el gas es un impulsor clave, existe también volatilidad endógena del mercado eléctrico en el medio plazo (por ejemplo, condiciones renovables, demanda residual y estructura horaria).

Las cuotas `renovables` y `fosiles` presentan alta autonomía: la mayor parte de su variabilidad se explica por shocks propios, lo que es consistente con restricciones técnicas y meteorológicas que dominan su dinámica a frecuencia mensual.

Por último, en el IPC dominan shocks propios al inicio, pero a partir de horizontes cercanos a un año aumentan las contribuciones de shocks energéticos (precio eléctrico y gas). Este resultado cuantifica la relevancia macroeconómica del canal energético en la variación del IPC dentro del sistema estimado.

5.1.4. Capacidad predictiva y evaluación fuera de muestra (2024)

Como validación complementaria, se evalúa la capacidad del VAR para predecir 2024 fuera de muestra. Los resultados se presentan mediante *fan charts* (Figs. 5.8–5.12). La Tabla 5.3 resume métricas de precisión.

Métricas de error de predicción

Tabla 5.3: Métricas de error de predicción fuera de la muestra (2024)

Variable	RMSE	MAPE (%)	Conclusión técnica
`renovables`	0.0659	9.53	Excelente precisión; captura la estacionalidad del mix.
`ipc_general`	0.7596	28.99	Error moderado; tendencia general bien identificada.
`fosiles`	0.0675	29.79	Ajuste aceptable de la dinámica de respaldo térmico.
`precio_gas`	14.192	38.25	Desviación significativa por shocks exógenos de oferta.
`precio_total`	34.435	58.68	Mayor incertidumbre; serie muy volátil y sensible a episodios extremos.

En conjunto, el modelo predice mejor variables con estacionalidad y restricciones físicas (cuotas del *mix*) que variables altamente expuestas a shocks externos (gas) o a picos de mercado (precio eléctrico). Este patrón es esperable y motiva el uso de XGBoost como alternativa flexible para predicción.

Fan charts: lectura cualitativa

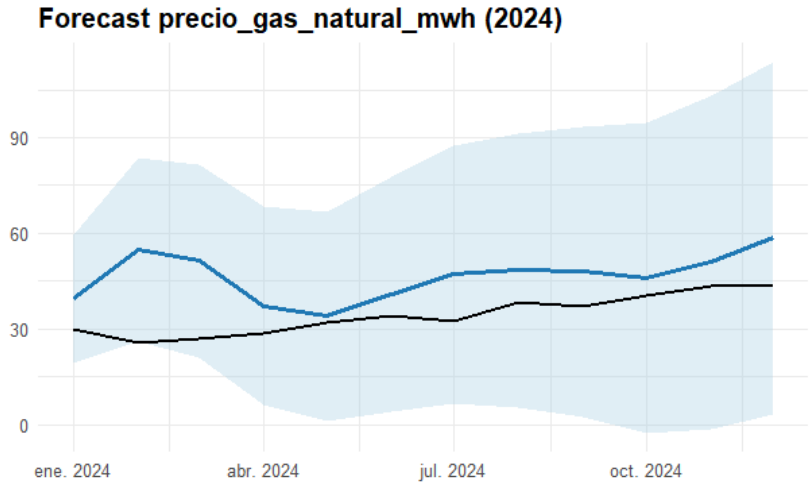


Figura 5.8: Fan chart del precio del gas natural para 2024.

En el precio del gas (Fig. 5.8), el modelo tiende a sobreestimar durante la primera mitad del año. Esto es compatible con un cambio de régimen posterior a la crisis que el VAR, basado en patrones históricos, tarda en internalizar.

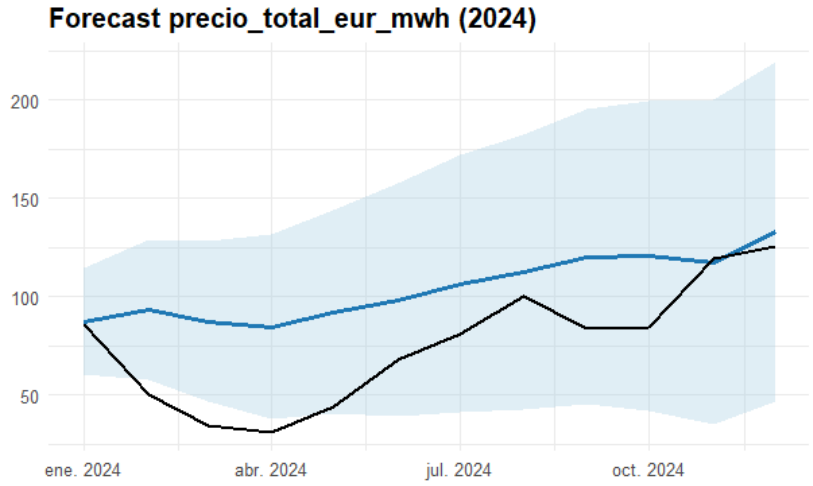


Figura 5.9: Fan chart del precio mayorista de la electricidad para 2024.

Para el precio eléctrico (Fig. 5.9), la predicción también sobreestima gran parte de 2024, situándose el observado cerca del límite inferior de las bandas en varios meses. Esto sugiere que 2024 presenta una dinámica de precios relativamente débil frente a la historia reciente, posiblemente ligada a normalización del gas y/o a condiciones favorables de producción renovable.

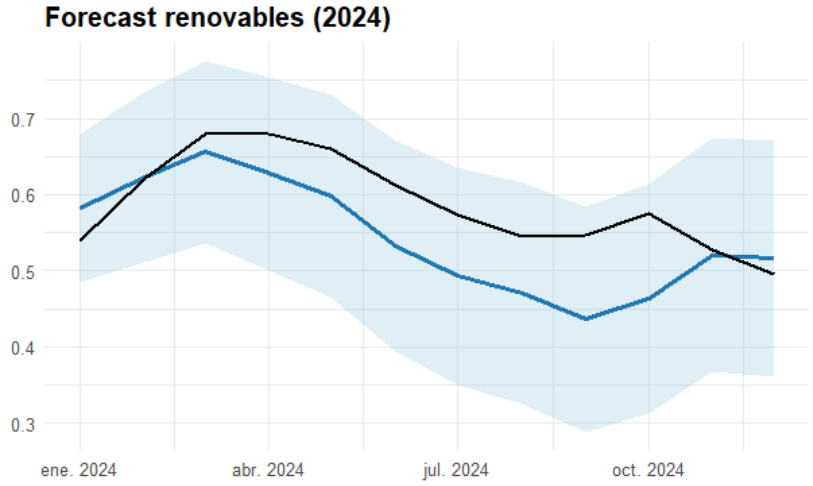


Figura 5.10: Fan chart de la cuota de renovables para 2024.

La cuota de renovables (Fig. 5.10) muestra el mejor ajuste: el modelo captura bien el perfil estacional y el observado sigue de cerca la predicción.

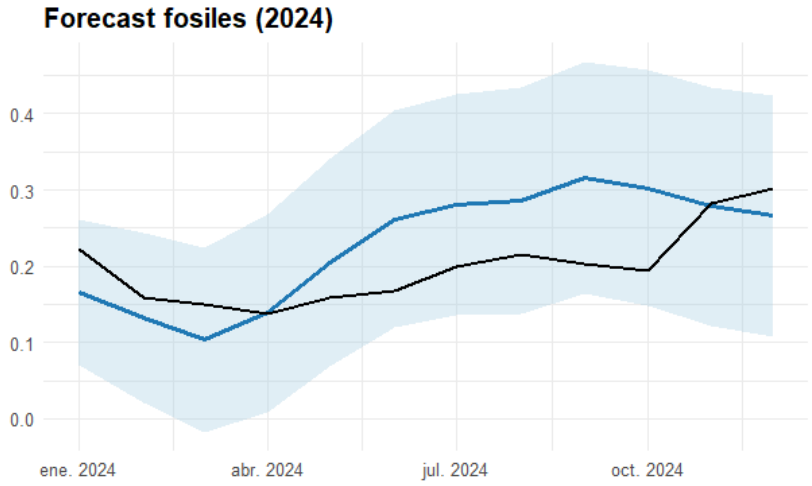


Figura 5.11: Fan chart de la cuota de tecnologías fósiles para 2024.

En fósiles (Fig. 5.11), el modelo infrapredice ligeramente al inicio del año, pero el observado se mantiene dentro de las bandas y el ajuste mejora hacia el final del periodo.

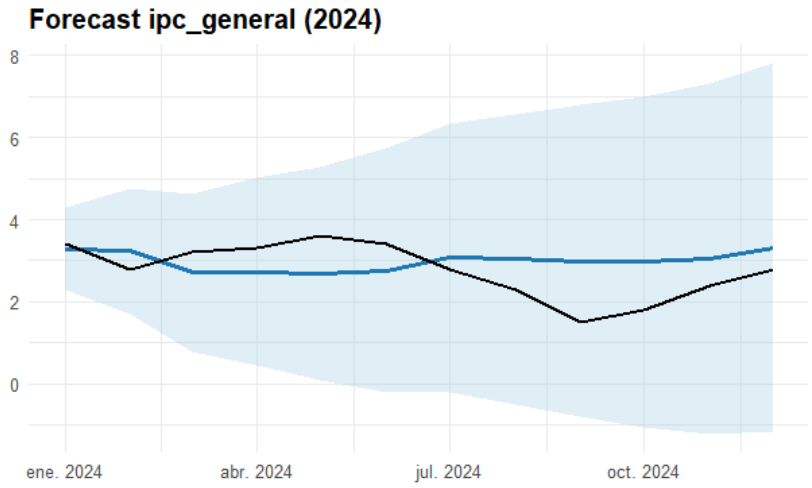


Figura 5.12: Fan chart del IPC general para 2024.

Para el IPC (Fig. 5.12), la predicción es cercana al inicio del año y luego el observado queda algo por debajo de la senda prevista, pero dentro de las bandas. En términos prácticos, el VAR parece útil como herramienta de seguimiento a corto/medio plazo, aunque no capta perfectamente cambios de régimen.

5.1.5. Discusión e implicaciones

Los resultados combinados de IRFs, FEVD y predicción apuntan a tres mensajes:

- **Gas como fuente externa de volatilidad:** el gas explica una fracción relevante de la variabilidad del precio eléctrico, especialmente a corto plazo. Esto cuantifica la exposición del mercado eléctrico a shocks internacionales.

- **Renovables como amortiguador (efecto moderado):** los shocks en cuota renovable se asocian con caídas del precio eléctrico y, con retraso, con una señal desinflacionaria en el IPC. El efecto existe, pero es moderado y con incertidumbre, lo que sugiere que la penetración renovable ayuda pero no elimina vulnerabilidad a shocks externos.

- **Pass-through electricidad → IPC:** el shock del precio mayorista se transmite al IPC con retrasos, alcanzando su mayor efecto en los meses posteriores. Este patrón es consistente con un canal energético relevante en la dinámica inflacionaria.

En todo caso, estas conclusiones deben leerse como condicionales al esquema de identificación (ordenamiento recursivo) y a la frecuencia mensual. Por ello, se complementa el análisis con evidencia predictiva y no lineal mediante XGBoost.

5.2. Resultados del modelo de ML: XGBoost

Los resultados del VAR–SVAR muestran que el sistema captura relaciones dinámicas plausibles, pero su capacidad predictiva se degrada cuando hay cambios de régimen. Dos motivos son especialmente relevantes: (i) el carácter lineal del VAR, que tiende a promediar relaciones que en la práctica cambian por tramos, y (ii) el coste en grados de libertad al incorporar muchos retardos y controles en una muestra mensual relativamente corta. En este contexto, se introduce un segundo bloque metodológico basado en *Machine Learning* para modelar no linealidades y explotar un conjunto de predictores de alta dimensionalidad.

5.2.1. El modelo XGBoost en entornos de alta dimensionalidad

Para este análisis se implementa **eXtreme Gradient Boosting (XGBoost)** (Chen y Guestrin 2016). A diferencia de los modelos autorregresivos lineales, XGBoost aprende una función no lineal mediante un ensamblado de árboles de decisión entrenados con *gradient boosting*. Esta arquitectura permite (i) capturar interacciones, (ii) acomodar umbrales y cambios de pendiente, y (iii) trabajar con muchos predictores sin imponer una forma funcional específica.

En este trabajo, el modelo se entrena con una muestra limitada (2011–2023; $N = 144$ observaciones) y un conjunto amplio de predictores ($P = 548$). Este régimen $P \gg N$ incrementa el riesgo de sobreajuste: el algoritmo puede ajustar muy bien el pasado y, aun así, generalizar mal.

Gestión del sobreajuste y regularización

Para mitigar el sobreajuste se aplica regularización y control explícito de complejidad en tres niveles:

- **Penalización L1/L2 (parámetros `alpha` y `lambda`):** en XGBoost, estas penalizaciones actúan sobre los *pesos de las hojas* (leaf weights) y la complejidad efectiva de los árboles, limitando ajustes extremos y favoreciendo soluciones más estables. En un entorno de alta dimensionalidad, un componente L1 ayuda a inducir parsimonia al penalizar soluciones con pesos innecesariamente grandes.
- **Submuestreo estocástico:** se fija `colsample_bytree`=0.7 y `subsample`=0.8. Al entrenar cada árbol con una fracción de columnas y observaciones, se reduce la dependencia entre árboles y se mejora la generalización.
- **Control de complejidad:** se restringe la profundidad (`max_depth` ≤ 3). Con datos mensuales y pocos años efectivos de entrenamiento, árboles profundos fragmentan en exceso el espacio de predictores y tienden a memorizar episodios idiosincráticos.

La Tabla 5.4 resume la configuración final seleccionada mediante validación temporal. La elección de un `eta` pequeño también ayuda a evitar que el modelo reaccione de forma demasiado agresiva a ruido de corto plazo.

Tabla 5.4: Configuración de hiperparámetros optimizados para XGBoost

Parámetro	Valor	Justificación técnica
`eta` (learning rate)	0.02	Convergencia gradual; reduce sobreajuste.
`max_depth`	2 o 3	Árboles poco profundos para evitar fragmentación excesiva.
`alpha` (L1)	0.5	Penaliza complejidad en hojas; favorece parsimonia efectiva.
`nrounds`	early stopping	Detiene el entrenamiento cuando no mejora en validación temporal.

5.2.2. Modelo XGBoost para el precio mayorista de la electricidad

Se estima un modelo XGBoost para `precio_total_eur_mwh`. El objetivo es doble: (i) mejorar la predicción fuera de muestra y (ii) extraer evidencia sobre no linealidades (umbrales) que un modelo lineal tiende a promediar. El entrenamiento usa 2011–2023 y 2024 se reserva como *test set*, evitando estrictamente el uso de información futura.

Capacidad predictiva y evaluación fuera de muestra

El *fan chart* para 2024 (Fig. 5.13) muestra que el modelo captura la tendencia general y la estabilización del precio hacia el tramo final del año. Sin embargo, aparece un sesgo de sobreestimación en el primer trimestre: el modelo no anticipa plenamente la magnitud de las caídas de febrero y marzo, coherentes con un episodio excepcional de demanda débil y alta disponibilidad hidráulica.

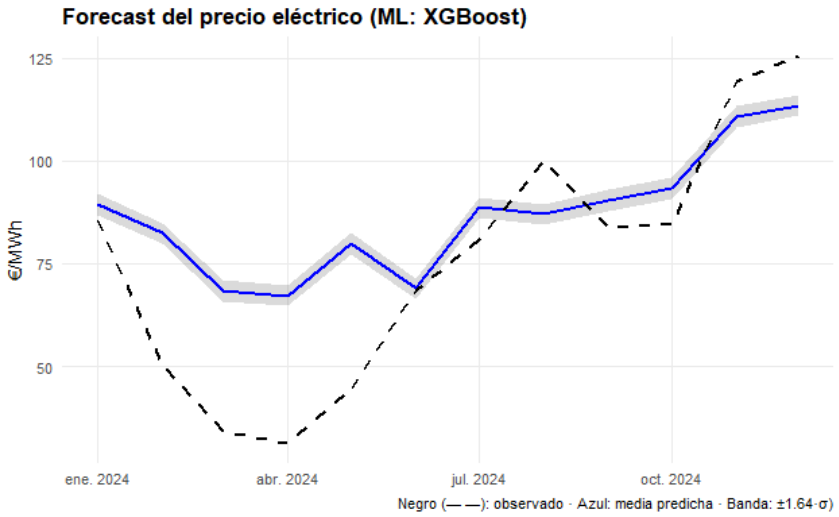


Figura 5.13: Fan chart del pronóstico XGBoost para el precio mayorista en 2024.

En términos cuantitativos, el desempeño en la muestra de prueba es:

$$\text{RMSE} = 21,1 \text{ €/MWh}, \qquad \text{MAPE} = 35,3\,\% \tag{5.1}$$

El MAPE supera el 30 %, pero debe interpretarse con cautela: cuando el precio observado cae a niveles muy bajos, el denominador del MAPE amplifica el error relativo aunque el error absoluto no sea extremo. Por eso se reporta conjuntamente RMSE, que es más estable ante meses con precios excepcionalmente bajos.

En conjunto, XGBoost mejora la capacidad de capturar cambios de régimen respecto al VAR, lo cual es coherente con la ventaja de un modelo no lineal que aprende interacciones entre gas, retardos y *mix*.

Importancia de variables: jerarquía de predictores

La importancia de variables (Fig. 5.14) muestra un patrón claro: el precio del gas natural (`precio_gas_natural_mwh`) y el primer retardo del precio eléctrico (`precio_total_eur_mwh_lag1`) dominan el poder predictivo.

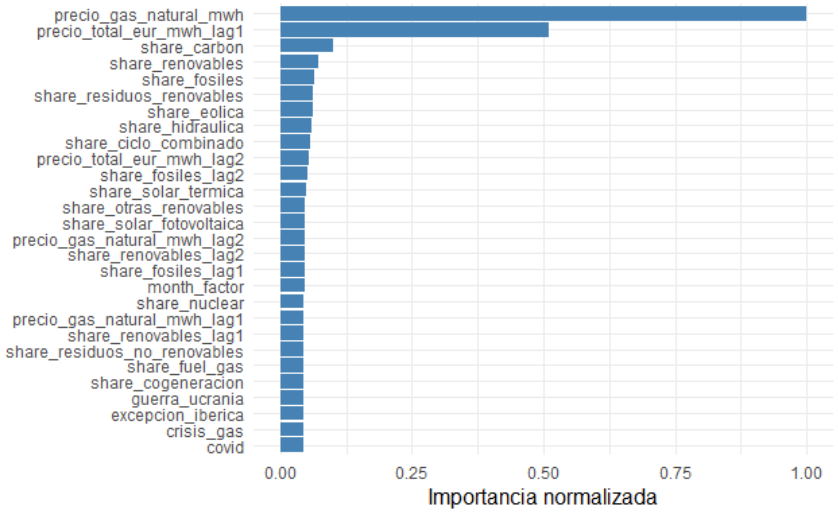


Figura 5.14: Importancia de variables (*Feature Importance*) en el modelo XGBoost.

Económicamente, esta jerarquía es coherente con dos hechos: (i) el gas sigue actuando como referencia de coste marginal en episodios relevantes del mercado mayorista, y (ii) el precio eléctrico presenta inercia, por lo que el retardo inmediato captura persistencia y propagación de shocks. Las dummies (guerra de Ucrania, excepción ibérica) aparecen con importancia reducida: su efecto se canaliza principalmente a través del gas y del propio precio eléctrico; una vez observadas esas variables, la etiqueta del evento aporta poca información adicional.

Efectos marginales y umbrales no lineales (PDP/ICE)

Para interpretar el modelo se emplean **Partial Dependence Plots (PDP)**. El PDP aproxima el efecto promedio de una variable manteniendo el resto en su distribución observada (Friedman 2001). Es importante subrayar que estos gráficos describen asociaciones aprendidas por el modelo, no efectos causales.

Dinámica del gas natural. El PDP del gas (Fig. 5.16) sugiere una no linealidad tipo "escalón": para valores inferiores a 40–50 €/MWh, el efecto sobre la electricidad es moderado; al superar el umbral de 50 €/MWh, la pendiente aumenta, indicando una sensibilidad mucho mayor del precio mayorista.

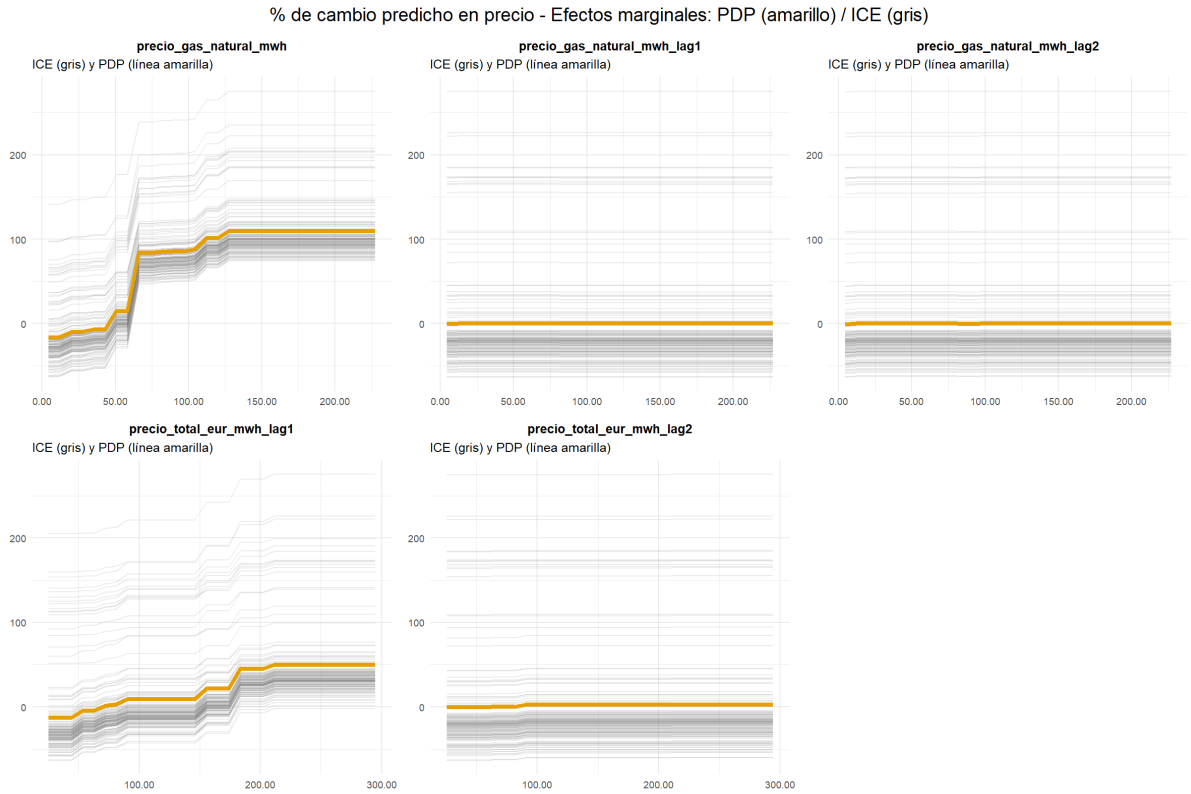


Figura 5.15: PDP para el precio del gas natural en el modelo del precio eléctrico.

Efectos del *mix*. Los PDP por cuotas tecnológicas aportan dos resultados útiles para interpretar política energética:

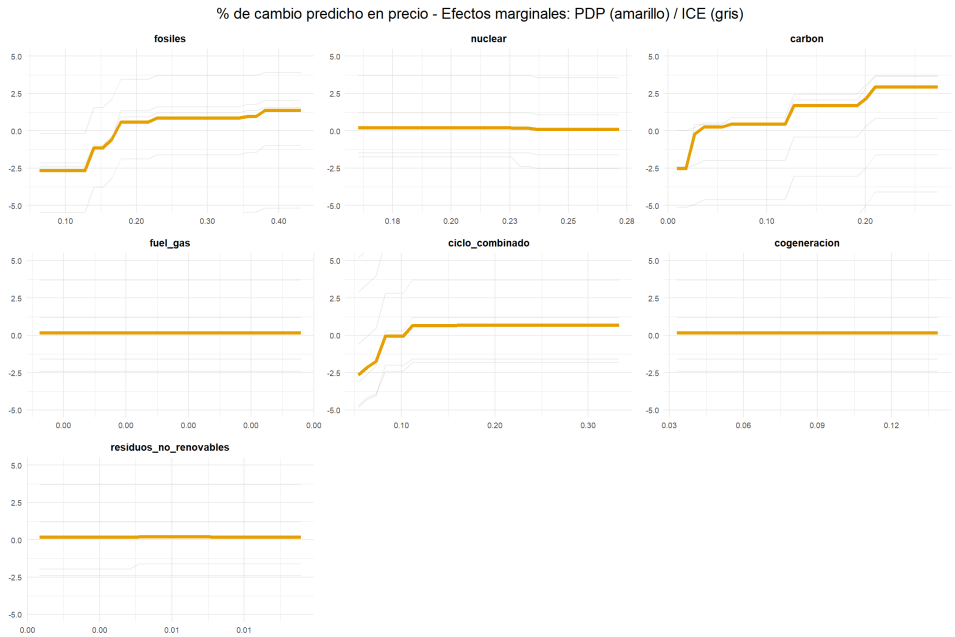


Figura 5.16: PDP para el precio del gas natural en el modelo del precio eléctrico.

- **Umbral de renovables (50 %):** el efecto moderador del precio es pequeño por debajo del 50 % de cuota renovable mensual, pero se vuelve más marcado cuando

se supera dicho umbral (caída adicional de 2–3 p.p. en términos relativos). Esto es consistente con un mecanismo de escala: la penetración renovable debe ser suficientemente alta para desplazar térmica del margen de forma más sistemática.

- **Señal fósil:** la cuota de carbón aparece asociada a aumentos del precio con pendiente alta. En cambio, el ciclo combinado muestra un efecto más moderado una vez controlado el precio del gas, sugiriendo que, en la muestra, parte del canal del ciclo combinado opera vía coste del combustible más que por su cuota física.

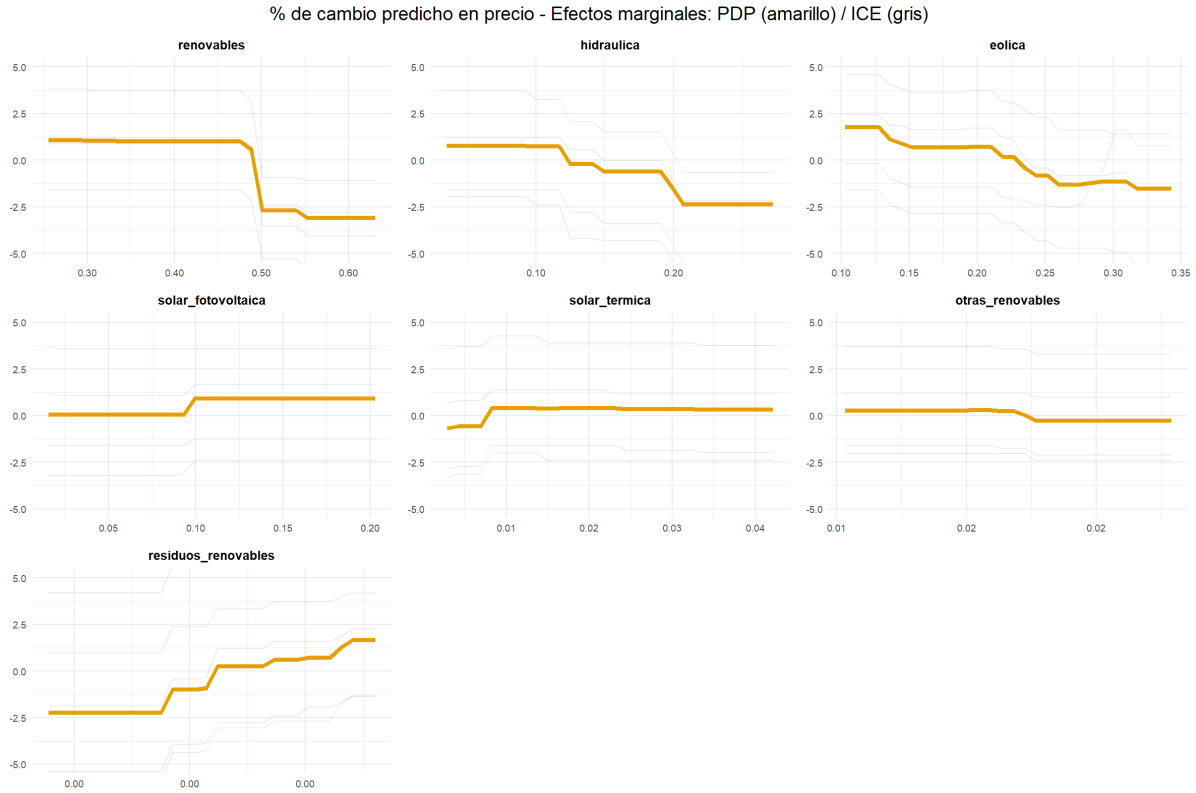


Figura 5.17: PDP para la cuota de renovables en el modelo del precio eléctrico.

Implicaciones económicas (precio eléctrico)

Los resultados del XGBoost refinan la lectura del VAR/SVAR en dos dimensiones:

1. **Riesgo no lineal del gas:** el impacto del gas sobre el precio eléctrico no parece proporcional en todo el rango; se intensifica por encima de 50 €/MWh.

2. **Efecto de escala renovable:** el efecto moderador del *mix* es más claro cuando la cuota renovable es elevada (alrededor del 50 % mensual), lo que apunta a umbrales operativos relevantes.

5.2.3. Modelo XGBoost para el IPC general

Se estima un segundo XGBoost con variable objetivo `ipc_general`. El objetivo es capturar la transmisión no lineal desde precios energéticos y composición del *mix* hacia el nivel de precios al consumo, y evaluar si existen umbrales en la respuesta del IPC que los modelos lineales suavizan.

Evaluación predictiva en 2024

Las métricas fuera de muestra (2024) son:

$$\text{RMSE} = 0,567 \text{ p.p.}, \qquad \text{MAPE} = 18,92\,\% \tag{5.2}$$

Estos valores implican un ajuste competitivo para una variable macro agregada. La Fig. 5.18 muestra que el modelo reproduce la desinflación de la primera mitad del año y el repunte final. La predicción se mantiene dentro de las bandas $\pm 1{,}64\hat{\sigma}$ (interpretadas como una referencia descriptiva, no como intervalos probabilísticos exactos).

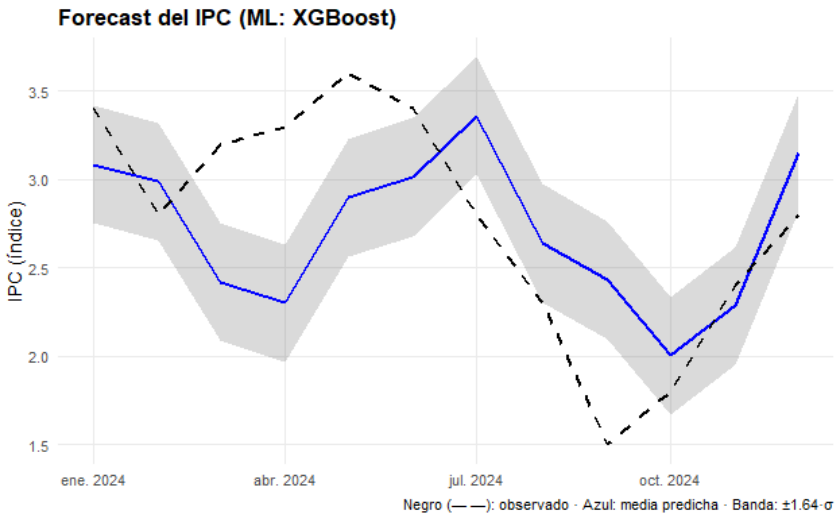


Figura 5.18: Fan chart del pronóstico XGBoost para el IPC general en 2024.

Importancia de variables: dominancia del canal energético

La Fig. 5.19 confirma el papel central del canal energético: el precio del gas y el precio eléctrico (contemporáneos y retardados) forman el núcleo explicativo. Las variables del *mix* aparecen en un segundo nivel, lo que sugiere que su efecto sobre el IPC opera principalmente de forma indirecta, modulando el precio mayorista.

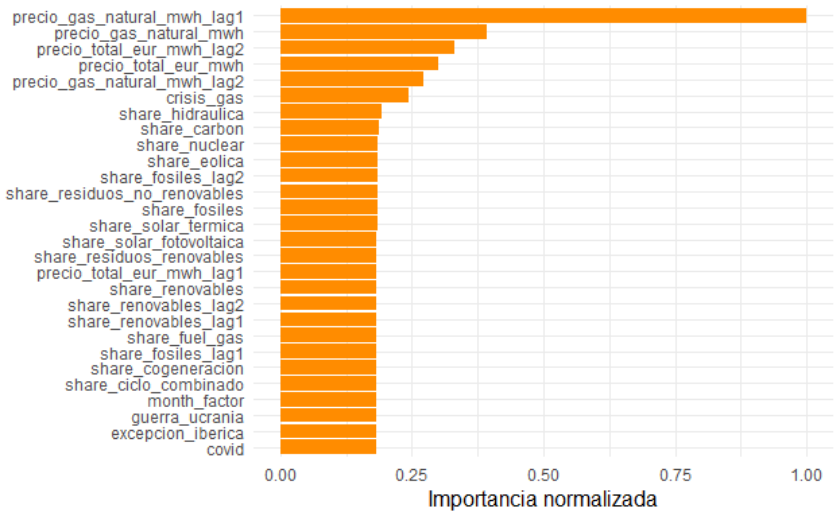


Figura 5.19: Importancia de variables en el modelo XGBoost del IPC.

PDP del IPC: umbrales e interpretación económica

1) Umbrales en precios energéticos. El PDP del gas sobre el IPC (Fig. 5.20) muestra una no linealidad marcada: por debajo de 40–50 €/MWh, el efecto promedio es reducido; al superar ese rango, el IPC predicho aumenta con mayor pendiente. Además, el efecto es más visible en retardos, lo que es coherente con transmisión gradual (rigideces nominales, facturación y efectos de segunda ronda).

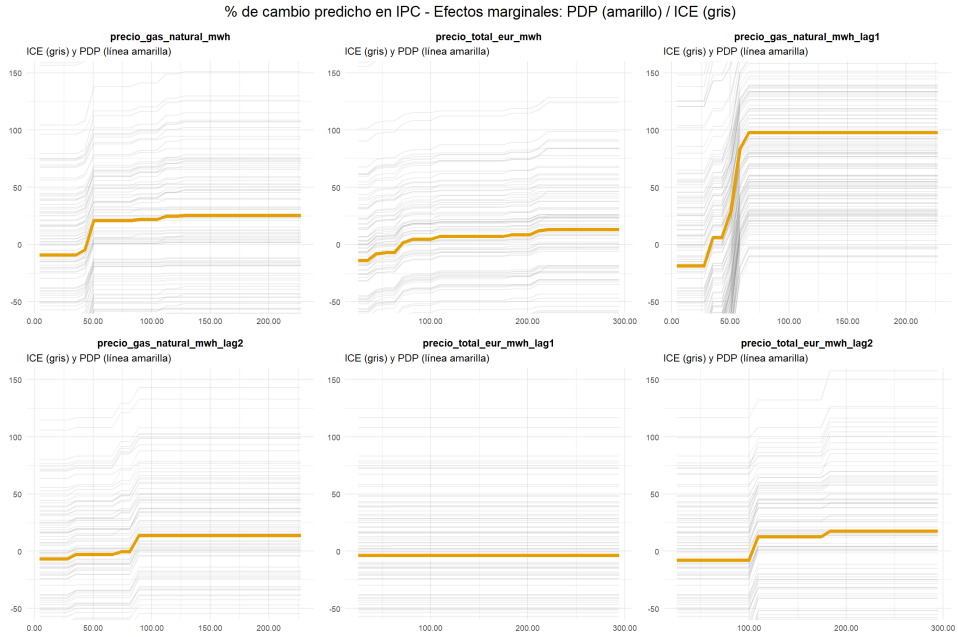


Figura 5.20: PDP del precio del gas sobre el IPC: evidencia de umbrales.

2) Cuota fósil una vez controlados los precios. Los PDP para `share_fosiles` y `share_ciclo_combinado` (Fig. 5.21) muestran un perfil plano o ligeramente negativo. Esto no implica que los fósiles "reduzcan" el IPC; indica que, condicionado a precios (gas y

electricidad) ya incluidos en el modelo, la cuota fósil aporta poca señal adicional. En otras palabras: el canal inflacionario de los fósiles queda capturado por los precios energéticos.

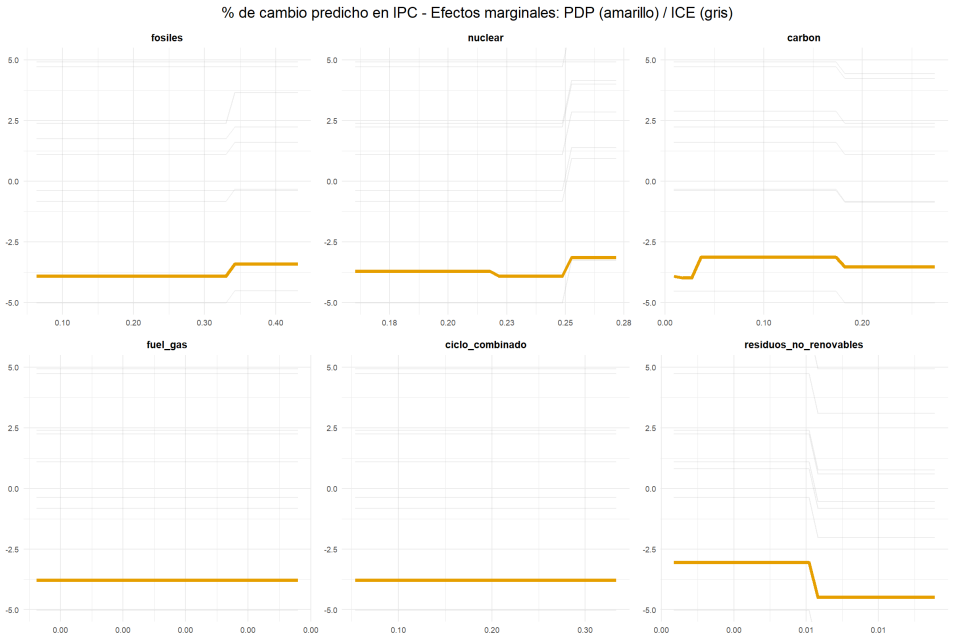


Figura 5.21: PDP de la cuota de tecnologías fósiles sobre el IPC (condicionado a precios).

3) Heterogeneidad dentro de las renovables. El PDP desagregado (Fig. 5.22) sugiere que eólica e hidráulica son las tecnologías con señal desinflacionaria más clara en el IPC (una vez controlados precios), mientras que otras tecnologías presentan perfiles más planos. Esto es compatible con diferencias en escala, perfil temporal y capacidad efectiva para desplazar generación marginal.

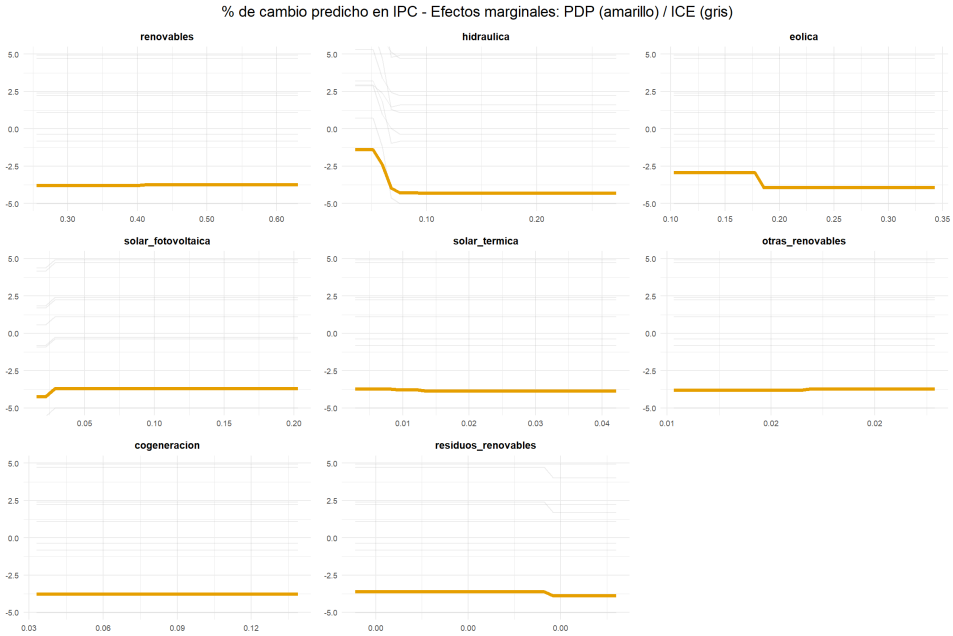


Figura 5.22: PDP desagregado: impacto diferencial de eólica e hidráulica en el IPC.

5.2.4. Discusión de los resultados

El análisis conjunto (precio eléctrico e IPC) aporta una narrativa integrada sobre transmisión de shocks energéticos en España. El resultado más robusto es la centralidad del gas como variable sistémica: domina la predicción del precio mayorista y, vía precio eléctrico y retardos, domina también la predicción del IPC.

El principal valor añadido del enfoque no lineal es la identificación empírica de un umbral operativo en torno a 50 €/MWh en el gas: por debajo de ese nivel, el sistema opera en un régimen relativamente estable; por encima, la sensibilidad del precio eléctrico (y posteriormente del IPC) aumenta. Esta lectura es consistente con un mercado marginalista donde, en escenarios de tensión, el ciclo combinado se convierte de forma más sistemática en tecnología marginal, amplificando el *pass-through*.

En paralelo, los resultados matizan la idea de que "más renovables siempre reduce precios". La evidencia del modelo sugiere efectos de escala: el impacto moderador se vuelve más claro cuando la penetración renovable mensual supera niveles elevados (cercanos al 50 %). Además, existe heterogeneidad tecnológica: eólica e hidráulica emergen como agentes de contención más visibles en el IPC, frente a otras tecnologías con señal más débil una vez controlados precios.

Por último, el desempeño en 2024 ilustra una lección metodológica: tras rupturas estructurales (pandemia y crisis energética), las relaciones económicas pueden volverse dependientes del régimen. En ese entorno, modelos flexibles como XGBoost son útiles no sólo para predecir, sino también para diagnosticar umbrales e interacciones; aun así, sus resultados deben leerse como asociaciones predictivas, no como estimaciones causales.

Capítulo 6

Conclusiones

Este TFM analiza la relación entre el *mix* de generación, los precios energéticos (gas y electricidad) y la inflación (IPC) en España durante 2010–2024, combinando un enfoque econométrico dinámico (VAR/SVAR) con un enfoque predictivo no lineal (XGBoost).

Los resultados del VAR/SVAR sugieren tres conclusiones principales. Primero, el precio del gas actúa como fuente externa de volatilidad: explica una parte relevante de la variabilidad del precio mayorista de la electricidad, especialmente en el corto plazo. Segundo, la composición del *mix* importa, pero su efecto a frecuencia mensual es moderado y con incertidumbre: un aumento exógeno de la cuota renovable se asocia con una reducción del precio mayorista y con una señal desinflacionaria posterior en el IPC, compatible con el *merit-order effect*, aunque el tamaño del efecto depende de la identificación y del horizonte. Tercero, existe evidencia de *pass-through* desde el precio mayorista hacia el IPC con retardos: el shock del precio eléctrico se transmite gradualmente al nivel general de precios.

El bloque de *machine learning* refuerza y matiza estas conclusiones. El modelo generado mediante el algoritmo XGBoost confirma la centralidad del gas y de la persistencia del precio de la electricidad como predictores dominantes. El valor añadido principal del enfoque no lineal es que identifica patrones dependientes del régimen: el impacto del gas sobre el precio eléctrico (y, posteriormente, sobre el IPC) se intensifica a partir de ciertos niveles, y el efecto moderador de las renovables aparece con mayor claridad cuando su penetración mensual es alta. Estos resultados aportan una lectura operativa: la transición energética reduce exposición al riesgo, pero la vulnerabilidad no desaparece mientras el gas siga fijando el precio marginal en episodios relevantes.

Los resultados apuntan a que la dinámica reciente de los precios energéticos en España está relacionada tanto con la normalización del precio del gas tras la crisis de 2021–2022 como con el aumento de la capacidad renovable. La evidencia indica que estos factores interactúan de forma no lineal.

Capítulo 7

Limitaciones y mejoras

Este trabajo tiene limitaciones que conviene explicitar para interpretar los resultados con rigor y para orientar investigación posterior.

7.1. Limitaciones

- **Dependencia de la identificación (SVAR).** La interpretación de los *shocks* estructurales es condicional al ordenamiento recursivo de Cholesky. Identificaciones alternativas (restricciones de signos o variables instrumentales) podrían modificar la magnitud y persistencia de las Funciones de Impulso-Respuesta reportadas.
- **Agregación temporal.** El uso de datos mensuales enmascara la volatilidad intradiaria del mercado eléctrico. Esto impide capturar fenómenos de alta frecuencia, como la fijación horaria del precio marginal o la coincidencia precisa entre picos de demanda y generación solar.
- **Causalidad y variables omitidas.** Aunque los modelos capturan dinámicas predictivas robustas, no establecen una causalidad estricta. Factores exógenos no incluidos explícitamente, como la meteorología detallada o cambios regulatorios menores, podrían influir simultáneamente en el *mix* y los precios.
- **Estabilidad paramétrica.** La presencia de eventos extremos (COVID-19, crisis bélica) introduce rupturas estructurales. A pesar del uso de *dummies*, estos cambios de régimen pueden afectar la estabilidad de los coeficientes estimados en el VAR a lo largo de la muestra completa.
- **Incertidumbre en XGBoost.** Las bandas de predicción del modelo de *machine learning* son aproximaciones descriptivas basadas en la varianza de los residuos y no deben interpretarse como intervalos de confianza probabilísticos formales.

7.2. Líneas de investigación futura

- **Datos de alta frecuencia.** Replicar el análisis con datos horarios o diarios para modelar explícitamente la tecnología marginal y cuantificar el *merit-order effect* con mayor precisión.
- **Identificación robusta.** Implementar esquemas de identificación alternativos en el SVAR (Sign Restrictions o IV-SVAR) para validar la robustez de los mecanismos de transmisión detectados.
- **Dinámicas de largo plazo (VECM).** Estimar un Modelo de Corrección de Errores Vectorial para analizar explícitamente la velocidad de ajuste hacia el equilibrio de largo plazo entre precios energéticos e inflación.
- **Modelos de cambio de régimen.** Utilizar *Threshold VAR* o *Markov-Switching VAR* para formalizar econométricamente los umbrales no lineales y los cambios de régimen detectados por el modelo XGBoost.
- **Desagregación del IPC.** Analizar los componentes del IPC (subyacente, alimentos, bienes industriales) por separado para distinguir los efectos directos de la energía de los efectos de segunda ronda.
- **Análisis contrafactual.** Aplicar métodos de Control Sintético o Diferencias en Diferencias para aislar y cuantificar el impacto neto de la "Excepción Ibérica" sobre la inflación final.
- **Interpretabilidad local (SHAP).** Incorporar valores SHAP al modelo de *machine learning* para explicar la contribución exacta de cada variable en meses específicos, mejorando la narrativa de episodios críticos.
- **Incertidumbre probabilística en ML.** Implementar *Quantile Regression XGBoost* o *Conformal Prediction* para generar intervalos de predicción con garantías estadísticas formales.

Bibliografía

Adolfsen, Jakob Feveile et al. (2024). *Gas price shocks and euro area inflation*. Working Paper Series 2905. European Central Bank. URL: https://www.ecb.europa.eu/pub/pdf/scpwps/ecb.wp2905~6b246d6bf4.en.pdf.

Bańbura, Marta et al. (2025). *A new model to forecast energy inflation in the euro area*. Working Paper Series 3062. European Central Bank. URL: https://www.ecb.europa.eu/pub/pdf/scpwps/ecb.wp3062~abe560353f.en.pdf.

Bergmeir, Christoph y José M. Benítez (2012). «On the Use of Cross-Validation for Time Series Predictor Evaluation». En: *Information Sciences* 191, págs. 192-213. DOI: 10.1016/j.ins.2011.12.028. URL: https://doi.org/10.1016/j.ins.2011.12.028.

Boeck, Sebastian y Tobias Zörner (2025). «Gas price shocks, uncertainty and price setting: Evidence from Italian firms». En: *Energy Economics*, pág. 108061.

Castro, César et al. (2017). «A new look at oil price pass-through into inflation: evidence from disaggregated European data». En: *Economia Politica* 34.1, págs. 55-82. URL: https://www.econstor.eu/handle/10419/172273.

Cevik, Serhan y Yueshu Zhao (2025). *Shocked: Electricity Price Volatility Spillovers in Europe*. IMF Working Paper 2025/007. International Monetary Fund. URL: https://www.imf.org/en/publications/wp/issues/2025/01/11/shocked-electricity-price-volatility-spillovers-in-europe-559701.

Chen, Tianqi y Carlos Guestrin (2016). «XGBoost: A Scalable Tree Boosting System». En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, págs. 785-794. DOI: 10.1145/2939672.2939785.

CNMC Data: Energía eléctrica – Precio de mercado (2024). Comisión Nacional de los Mercados y la Competencia (CNMC). URL: https://data.cnmc.es/energia/energia-electrica/precio-de-mercado.

Commission approves Spanish and Portuguese measures aimed at reducing the wholesale electricity price (2022). European Commission. URL: https://ec.europa.eu/commission/presscorner/detail/it/ip_22_3550.

Cubero, J. Julián et al. (2025). *Reaping the benefits of renewable energy in the Spanish economy*. Inf. téc. BBVA Research. URL: https://www.bbvaresearch.com/wp-content/uploads/2025/02/EW_Reaping_the_benefits_edi2docxFinal.pdf.

Energy prices and security of supply (2024). Council of the European Union. URL: https://www.consilium.europa.eu/en/policies/energy-prices-and-security-of-supply/.

ESIOS REE – Mercados y precios (2024). Red Eléctrica de España (REE). URL: https://www.esios.ree.es/es/mercados-y-precios.

Fleschutz, Nils, David Pozo y Andreas Zucker (2020). *The unintended consequences of the policy based demand response (PBDR) for reducing carbon emissions*. arXiv. DOI: 10.1016/j.apenergy.2021.117040. URL: https://doi.org/10.1016/j.apenergy.2021.117040.

Friedman, Jerome H. (2001). «Greedy Function Approximation: A Gradient Boosting Machine». En: *The Annals of Statistics* 29.5, págs. 1189-1232. DOI: 10.1214/aos/1013203451.

Gelabert, Liliana, Xavier Labandeira y Pedro Linares (2011a). «An assessment of the effects of renewable generation on the Spanish electricity market». En: *Energy Policy* 39.9, págs. 5696-5706. DOI: 10.1016/j.enpol.2011.06.059. URL: https://doi.org/10.1016/j.enpol.2011.06.059.

— (2011b). «An ex-post analysis of the effect of renewables and cogeneration on Spanish electricity prices». En: *Energy Economics* 33.S1, S59-S65. DOI: 10.1016/j.eneco.2011.07.027.

Hidalgo-Pérez, Manuel et al. (2024). «The Iberian exception: Estimating the impact of a cap on gas prices for electricity generation on consumer prices and market dynamics». En: *Energy Policy* 188, pág. 114092. DOI: 10.1016/j.enpol.2024.114092. URL: https://www.sciencedirect.com/science/article/pii/S0301421524001125.

Hyndman, Rob J. y George Athanasopoulos (2018). *Forecasting: Principles and Practice*. 2.ª ed. OTexts. URL: https://otexts.com/fpp2/.

INE: IPC – Índice de Precios de Consumo (metodología y series) (2024). Instituto Nacional de Estadística (INE). URL: https://www.ine.es/.

Kilian, Lutz (2009). «Not All Oil Price Shocks Are Alike: Disentangling Demand and Supply Shocks in the Crude Oil Market». En: *American Economic Review* 99.3, págs. 1053-1069. DOI: 10.1257/aer.99.3.1053.

López, Lucia et al. (2024). *The pass-through to inflation of gas price shocks*. Working Paper Series 2968. European Central Bank. URL: https://www.ecb.europa.eu/pub/pdf/scpwps/ecb.wp2968~e514c92723.en.pdf.

Lütkepohl, Helmut (2005). *New Introduction to Multiple Time Series Analysis*. Springer. DOI: 10.1007/978-3-540-27752-1.

Markowski, Łukasz y Kamil Kotliński (2023). «Renewables, Energy Mix and Inflation in the European Union Countries». En: *Energies* 16.23, pág. 7808. DOI: 10.3390/en16237808. URL: https://www.mdpi.com/1996-1073/16/23/7808.

Martínez, F. G. et al. (2023). *The Spanish electricity sector in the face of rising gas prices*. Inf. téc. Banco de España. URL: https://www.bde.es/f/webbe/SES/Secciones/Publicaciones/PublicacionesSeriadas/DocumentosOcasionales/23/Files/do2316e.pdf.

Méjean, Isabelle (2023). *Energy shocks: How much have they affected inflation in France?* URL: https://www.insee.fr/en/statistiques/7667762?sommaire=7667914.

Peña, Juan Ignacio (2024). «A note on hydropower as a marginal price setter for Spain's electricity market in 2021–2022». En: *Utilities Policy* 87, pág. 101726. DOI: 10.1016/j.jup.2024.101726.

Quintana, Javier (2024). *Recent developments in wholesale electricity prices in Spain: the role of renewable energy*. Inf. téc. Banco de España. URL: https://www.bde.es/wbe/en/publicaciones/analisis-economico-investigacion/boletin-economico/2024t3-articulo-09-el-impacto-de-las-energias-renovables-sobre-el-precio-mayorista-de-la-electricidad.html.

Rabobank (2025). *Renewables are deflationary*. URL: https://www.suerf.org/wp-content/uploads/2025/03/SUERF-Policy-Brief-1112_Serrano-DeGroot-Ruiz_vanGeffen-Wijffelaars.pdf.

Robinson, David et al. (2023). *The Iberian Exception: An overview of its effects over its first 100 days*. Oxford Institute for Energy Studies / arXiv. URL: https://www.oxfordenergy.org/wpcms/wp-content/uploads/2023/11/EL-50-The-Iberian-Exception.pdf.

Ruiz, Enrique et al. (2024). «The effects of the Iberian exception mechanism on wholesale electricity prices and inflation: A synthetic control analysis». En: *Applied Economics Letters*. DOI: 10.1080/13504851.2024.2425834. URL: https://doi.org/10.1080/13504851.2024.2425834.

Sensfuß, Frank, Mario Ragwitz y Massimo Genoese (2008). «The merit-order effect: A detailed analysis of the price effect of renewable electricity generation on spot market prices in Germany». En: *Energy Policy* 36.8, págs. 3076-3084. DOI: 10.1016/j.enpol.2008.03.035.

Sims, Christopher A. (1980). «Macroeconomics and Reality». En: *Econometrica* 48.1, págs. 1-48. DOI: 10.2307/1912017.

Sims, Christopher A., James H. Stock y Mark W. Watson (1990). «Inference in Linear Time Series Models with Some Unit Roots». En: *Econometrica* 58.1, págs. 113-144. DOI: 10.2307/2938337.

Topan, Ligia et al. (2020). «Oil price pass-through into inflation in Spain at national and regional level». En: *SERIEs* 11.4, págs. 561-583. DOI: 10.1007/s13209-020-00222-4. URL: https://doi.org/10.1007/s13209-020-00222-4.